

Санкт–Петербургский государственный университет

ИВАНОВ Иван Иванович

Выпускная квалификационная работа

***То, на что ты уже через полгода будешь смотреть со
слезами***

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2015 «Прикладная
математика, фундаментальная информатика и программирование»

Профиль «Исследование и проектирование систем управления
и обработки сигналов»

Научный руководитель:

профессор, кафедра компьютерных технологий
и систем, д.ф. - м.н. Веремей Евгений Игоревич

Рецензент:

профессор, кафедра компьютерных технологий
и систем, д.ф. - м.н. Веремей Евгений Игоревич

Санкт-Петербург

2026 г.

Содержание

Введение	3
Постановка задачи	6
Обзор литературы	8
Глава 1. Формальная постановка задачи и предположения	13
1.1. Орбитали как целеориентированные сегменты	13
1.2. Limited LTV и долгосрочный эффект	14
1.3. Переходы между орбиталями в А/Б-экспериментах	16
1.4. Поставленные задачи оценки и эталонные методы	17
Выводы	21
Заключение	22
Список литературы	23

Введение

Оценка долгосрочного эффекта онлайн-экспериментов признаётся одной из наиболее сложных задач как в академических исследованиях, так и в индустриальной практике. Классические подходы к А/Б-тестированию хорошо приспособлены для измерения краткосрочных эффектов воздействий, однако с трудом улавливают отложенные и устойчивые сдвиги в ключевых бизнес-метриках, таких как пожизненная ценность клиента (customer lifetime value, LTV или CLV) [1, 12]. Ряд работ показывает, что оптимизация исключительно под краткосрочные исходы рискованна: ранние выигрыши могут со временем уменьшаться или сменяться потерями вследствие изменения паттернов вовлечённости пользователей [20, 11, 10, 2].

Чтобы преодолеть этот разрыв, в литературе развивается несколько направлений. Одно из наиболее заметных — использование *суррогатных* (проху) метрик, когда краткосрочные наблюдаемые индикаторы применяются для предсказания долгосрочных исходов. Так, в исследованиях Google предложены подходы к построению оптимальных прокси-метрик на основе истории прошлых А/Б-тестов: показано, что композитные суррогаты заметно улучшают принятие решений по сравнению с одиночной метрикой [23]. В работах LinkedIn продемонстрированы методы аппроксимации долгосрочных метрик по краткосрочным ковариатам, позволяющие сокращать длительность экспериментов при сохранении предсказательной способности [3]. Netflix развивает это направление, обучая прокси-метрики на исторических экспериментах и подчёркивая важность согласованности направления краткосрочных сигналов и долгосрочных целей [25].

Параллельное направление связано с поведенческой сегментацией клиентской базы. Классический RFM-анализ (Recency, Frequency, Monetary value) на протяжении десятилетий используется как базовый инструмент сегментации: он группирует пользователей по характеристикам транзакционного поведения и даёт интуитивно понятные и применимые на практике инсайты для бизнес-стратегии [6, 19]. Дальнейшее развитие этих идей — модели жизненного цикла клиента (Pareto/NBD, BG/NBD) и подходы к описанию динамики поведения, в том числе скрытые марковские модели отношений с

клиентом [21, 22, 4, 5, 14].

В настоящей работе предлагается подход, в котором долгосрочные эффекты А/Б-экспериментов оцениваются через *целеориентированную* поведенческую сегментацию пользователей. Каждый сегмент определяется условиями над пользователем и историей его активности в системе; сами условия подбираются так, чтобы внутри сегмента группировались пользователи с похожими целевыми характеристиками (например, GMV, удержанием, интенсивностью вовлечённости). Такие сегменты мы называем *орбиталями* и анализируем не столько сами их статические характеристики, сколько *траектории* пользователей между ними. В отличие от статических когорт, такая динамическая сегментация постоянно обновляет принадлежность пользователей к сегментам, преодолевая ограничения традиционных подходов, не учитывающих временную динамику [18, 26, 15]. По духу метод близок к работам, в которых поведение пользователей описывается как скрытый марковский процесс [14, 16], однако вместо фиксированных скрытых состояний используются непосредственно орбитали, а наблюдаемым итогом эксперимента становится финальное распределение пользователей по ним.

В работе формулируются три ключевых результата:

- вводится понятие *орбиталей* — целеориентированной поведенческой сегментации, обеспечивающей надёжную и интерпретируемую оценку долгосрочных эффектов по коротким экспериментам;
- формализуется использование *динамики переходов* между орбиталями как механизма причинного вывода, связывающего ближайшие поведенческие изменения с будущей ценностью;
- метод валидируется на реальных данных А/Б-тестов крупномасштабной e-commerce платформы, и демонстрируется, что орбитали улучшают качество принимаемых решений, не нарушая темпа быстрых экспериментальных циклов.

Предлагаемый подход закрывает важный разрыв в современном экспериментировании: рассогласованность между быстрыми циклами разработки

продукта и стратегической потребностью смотреть на долгосрочные эффекты. Опираясь на наблюдаемые траектории пользователей, орбитали дают прозрачную и удобную в эксплуатации альтернативу непрозрачным суррогатным моделям и при этом не требуют проведения длительных экспериментов.

Постановка задачи

В современных платформах А/Б-эксперименты вынуждены давать ответ за ограниченное время — от нескольких дней до нескольких недель, — тогда как ключевые бизнес-метрики (удержание, пожизненная ценность пользователя) формируются на горизонтах, существенно превышающих длительность одного теста [12, 10, 24]. Прямые оценки долгосрочного эффекта через продолжительные эксперименты сопровождаются ростом стоимости, операционных рисков и эффектов выживаемости и потому плохо встраиваются в быстрые циклы разработки [11, 10, 8]. Альтернативные подходы на основе суррогатных моделей опираются на модели «чёрного ящика» и требуют постоянной перекалибровки при изменениях продукта [23, 3, 25]. В результате между быстрыми экспериментальными циклами и стратегической потребностью смотреть на долгосрочные эффекты сохраняется устойчивый разрыв.

Чтобы конкретизировать характер этого разрыва, рассмотрим реальный пример из практики. В рассматриваемом эксперименте пользователям тестовой группы предлагалась возможность «купить сейчас, заплатить позже» (Buy Now, Pay Later, BNPL) в маркетплейсе. На рис. ?? показано, как менялась разница в показателях удержания пользователей контрольной (А) и тестовой (В) групп.

На старте эксперимента уровни удержания в обеих группах были близки. По ходу эксперимента BNPL воспринималась пользователями как ценная функциональность, что приводило к росту удержания в тестовой группе. К моменту завершения эксперимента сформировавшийся разрыв сохранялся в течение длительного периода. Этот пример показывает, что долгосрочные поведенческие паттерны могут меняться *в течение* эксперимента и что соответствующие эффекты допустимо оценивать ещё до его формального окончания: тестовая группа ожидаемо приносит большую ценность независимо от итогового решения по самой функциональности.

Опираясь на этот пример, мы интерпретируем долгосрочный эффект не как ответ на гипотетический вопрос «что произошло бы, если бы эксперимент длился бесконечно?», а более операциональным образом: «как именно

эксперимент уже изменил долгосрочное поведение пользователей?». Такая постановка позволяет работать с фактически наблюдаемыми поведенческими сдвигами и оценивать их до того, как реализуется вся будущая выручка, — именно эта интерпретация лежит в основе предлагаемого метода Orbitals.

Неформально задача исследования состоит в следующем. Дана платформа, на которой проводится А/Б-эксперимент с разделением пользователей на контрольную (А) и тестовую (В) группы; известны их характеристики и история активности до и в течение эксперимента. Требуется построить *целесоориентированную* поведенческую сегментацию пользователей (орбитали) и метод оценки долгосрочного эффекта эксперимента, который удовлетворяет следующим требованиям:

- (i) использует только данные, наблюдаемые в течение самого теста;
- (ii) опирается на изменение распределения пользователей по орбиталим и переходы между ними;
- (iii) сохраняет интерпретируемость относительно исходных поведенческих сегментов;
- (iv) встраивается в существующие пайплайны А/Б-тестирования без существенной перестройки инфраструктуры.

Обзор литературы

Тема диссертации находится на пересечении трёх направлений: оценки долгосрочного эффекта онлайн-экспериментов, моделирования поведения пользователей и методологии А/Б-тестирования. Ниже разбираются основные из этих направлений, причём внимание уделяется не только их достижениям, но и ограничениям, которые проявляются в задаче масштабируемой и интерпретируемой оценки LTV.

Краткосрочные А/Б-эксперименты и прокси-метрики

А/Б-тестирование давно закрепилось как стандартный инструмент оценки продуктовых изменений на онлайн-платформах [12]. Из-за операционных ограничений большинство экспериментов планируется так, чтобы давать ответ за дни или недели, и команды вынуждены опираться на краткосрочные прокси-метрики — кликабельность (CTR), длительность сессии, немедленную конверсию. Такие показатели удобно измерять, но они нередко слабо связаны с долгосрочными бизнес-исходами.

Эта проблема систематически разбирается в литературе об ошибках интерпретации онлайн-экспериментов. В работе [2] описана характерная подборка типичных «ловушек» (так называемая «dirty dozen»), среди которых — интерпретация краткосрочного выигрыша как устойчивого долгосрочного эффекта. Хрестоматийный пример — увеличение объёма рекламных показов: оно даёт немедленный прирост выручки, но со временем снижает удовлетворённость пользователей и повышает отток. Именно такое рассогласование заставляет искать методы, способные переводить краткосрочные сигналы в надёжные оценки долгосрочного эффекта.

Длительные эксперименты

Самая очевидная стратегия — продлить сам эксперимент. Опыт Netflix [25] и Microsoft [20] показывает, что длительные дизайны действительно позволяют наблюдать отложенные исходы, в первую очередь — изменения удержания и частоты покупок. Однако такие эксперименты дороги, медленно дают ответ

и оставляют бизнес под продолжительным риском. К этому добавляется проблема *выживаемости* (survivorship bias): со временем в окне анализа остаются преимущественно наиболее вовлечённые пользователи, что искажает оценку эффекта на уровне всей популяции.

Суррогатное моделирование долгосрочных эффектов

Чтобы совместить быстрые циклы экспериментирования с потребностью в долгосрочной оценке, развиваются методы *суррогатного моделирования*: долгосрочный исход прогнозируется по краткосрочным поведенческим сигналам. По сути задача сводится к выбору или построению такой метрики (или композитной метрики) на ранних этапах жизненного цикла пользователя, которая сильно коррелирует с будущей ценностью. В индустриальной практике эта конструкция получила название *Surrogate Index* [25]: она ускоряет принятие решений, не разрывая их со стратегическими целями бизнеса.

Современные реализации опираются на машинное обучение и выучивают сложные нелинейные отображения из ранних поведенческих признаков в LTV [8]. На платформах Netflix и Microsoft такие модели используются для прогнозирования последующего вовлечения и выручки по ранним паттернам взаимодействия, а их калибровка проводится на исторических А/Б-тестах для обеспечения надёжности [25, 20].

При всей выразительности эти модели обычно слабо интерпретируемы и требуют значительного объёма исторических данных для калибровки. Кроме того, они опираются на так называемое *предположение суррогатности*: краткосрочная прокси-метрика должна не только коррелировать с долгосрочным исходом, но и полностью опосредовать причинный эффект воздействия на него [25]. Формально это требование сформулировано Prentice [17] в контексте клинических испытаний: все причинные пути от воздействия к итоговому исходу должны проходить исключительно через суррогат. Практика показывает, что суррогатные индексы, обученные на краткосрочных метриках, успешно предсказывают долгосрочные исходы — это подтверждено валидацией более чем на 200 А/Б-тестах [25], — однако само предположение суррогатности трудно проверять, и оно может нарушаться из-за эффектов

новизны, привыкания и скрытых искажающих факторов.

Когортный анализ и поведенческая сегментация

Когортный анализ относится к базовым техникам клиентской аналитики и традиционно применяется для разложения LTV на компоненты: удержание, частоту и денежную ценность (RFM) [19]. Группируя пользователей по общим признакам — например, по месяцу регистрации или уровню активности, — команды получают возможность отслеживать эволюцию ключевых метрик во времени.

В диссертации эта традиция продолжается, но акцент смещается с описательной сегментации на *целеориентированную*. В отличие от статических когортных определений, орбитали выводятся из предсказательной задачи — прогнозирования будущей активности пользователя — с помощью решающих правил, извлечённых из ансамблевых древесных моделей машинного обучения, широко применяемых на практике. Благодаря этому получаемые сегменты остаются интерпретируемыми и одновременно настроены под задачу оценки долгосрочного эффекта.

Важной теоретической опорой для связи RFM-признаков с пожизненной ценностью служит работа Fader, Hardie и Lee [6], в которой вводится понятие *iso-value curves* — линий уровня в пространстве RFM, объединяющих пользователей с одинаковой ожидаемой LTV. Авторы показывают, что разные комбинации давности, частоты и денежной ценности могут соответствовать сопоставимой долгосрочной ценности, и тем самым ставят под сомнение упрощённые сегментационные схемы. Этот результат поддерживает выбранный подход: вместо фиксированных RFM-эвристик отображение поведенческих паттернов в LTV выучивается из данных, что обеспечивает более точное и многогранное представление архетипов пользователей.

Параметрические модели поведения пользователей

Существенный пласт литературы посвящён вероятностным моделям активности и оттока. Среди наиболее известных — Pareto/NBD и BG/NBD [4], описывающие два сопряжённых процесса: интенсивность транзакций и выбы-

тие пользователя. Эти модели позволяют прогнозировать будущие покупки и широко применяются в анализе клиентской базы.

В рамках предварительного исследования мы применяли Pareto/NBD для описания активности пользователей и оценки LTV, выраженной в днях вовлечённости. Модель удовлетворительно воспроизводит агрегированные паттерны удержания, но оказывается менее эффективной при работе с гетерогенной пользовательской популяцией и короткими окнами наблюдения. К этому добавляется характерное ограничение её предпосылок — в частности, постоянной интенсивности выбытия, — которое нередко нарушается в динамичных продуктовых средах.

В более поздних работах изучается применение моделей времени до события и анализа выживаемости для оценки долгосрочных эффектов [13]. Эти подходы, однако, требуют сложного отбора признаков и плохо переносятся на широкий спектр типов экспериментов.

Uplift-моделирование и переходы между состояниями

Uplift-моделирование нацелено на оценку индивидуального эффекта воздействия и служит основой для персонализированных решений. Среди современных подходов выделяется *Uplift Random Forest* [7], расширяющий алгоритм случайного леса за счёт критерия расщепления, ориентированного на гетерогенный эффект. Это позволяет выявлять подгруппы, в которых воздействие оказывает наиболее сильное положительное или отрицательное влияние, при сохранении устойчивости за счёт ансамблирования. Несмотря на потенциал, такие методы чувствительны к шуму и требуют больших объёмов выборки для надёжной оценки эффектов на индивидуальном уровне.

Предлагаемый подход дополняет uplift-моделирование, перенося фокус с индивидуальных эффектов на *групповые переходы* между поведенческими состояниями. Описывая то, как воздействие сдвигает распределение пользователей по орбиталям, мы получаем причинную интерпретацию, устойчивую к шуму и применимую на практике. По духу подход близок к марковским моделям отношений с клиентом [16, 14], но адаптирован к специфике онлайн-экспериментов и краткосрочных интервенций.

Выводы по обзору

Существующие подходы предоставляют богатый инструментарий для оценки долгосрочных эффектов, однако каждое из направлений вынуждено идти на компромисс между интерпретируемостью, масштабируемостью и надёжностью. Длительные эксперименты дают наиболее точную оценку, но дороги и подвержены эффектам выживаемости. Суррогатные модели ускоряют принятие решений ценой интерпретируемости и опираются на сложно проверяемое предположение суррогатности. Параметрические модели поведения и анализ выживаемости строятся на сильных допущениях и плохо переносятся на разнородные эксперименты. Uplift-моделирование требует значительных объёмов данных и оценивает эффект на индивидуальном уровне, что затрудняет его применение для стратегических решений.

Метод Orbitals закрывает обозначенный разрыв: он соединяет прозрачность когортного анализа с предсказательной силой машинного обучения и сводит оценку долгосрочного эффекта к анализу переходов между целеориентированными поведенческими сегментами. Такая постановка естественно опирается на операциональное определение долгосрочного эффекта и требования к методу, которые сформулированы в главе «Постановка задачи».

Глава 1. Формальная постановка задачи и предположения

В этой главе формализуются основные понятия и обозначения, используемые в дальнейшем. Сначала уточняется постановка задачи и вводятся обозначения, затем для формального определения долгосрочного эффекта вводится понятие ограниченной пожизненной ценности (limited LTV, ILTV), после чего показывается как эти конструкции применяются для А/Б эксперимента.

Ключевая идея подхода состоит в том, что долгосрочное воздействие экспериментального изменения проявляется не столько в смене поведения *внутри* орбиталей, сколько в *перераспределении пользователей между орбиталями*. Орбитали задают устойчивые **архетипы поведения**, а сам эффект эксперимента реализуется за счёт того, что доли пользователей **принадлежащих конкретным архетипам** меняются. Это допущение является центральным для предлагаемой схемы и **в экспериментальной части работы** будет поддержано эмпирическими наблюдениями.

Второе важное отличие нашего подхода состоит в **выборе объекта** оценивания. Мы стремимся оценить не гипотетический эффект бесконечно продолжительного воздействия, а тот долгосрочный эффект, который *уже сформировался* к моменту окончания эксперимента. Такая цель согласуется с типичными ограничениями на длительность А/Б-экспериментов и проще реализуема на практике, хотя и не устраняет всех проблем краткосрочного окна (например, эффекта новизны).

1.1 Орбитали как целеориентированные сегменты

В **нашем подходе** поведение пользователей описывается через *орбитали* — поведенческие сегменты, построенные с учётом целевой метрики (**LTV или её прокси**) и определённые интерпретируемыми правилами над признаками пользователя. Сегментация является *целеориентированной* (target-aware): орбитали конструируются так, чтобы хорошо предсказывать будущую ценность, а не только описывать текущие различия пользователей.

Формально множество орбиталей обозначим через $\mathcal{C}$. Для каждого пользователя u и момента времени t определена его орбитальная принадлежность

$c_u(t) \in \mathcal{C}$. Правила, определяющие орбитали, считаются зафиксированными во времени и зависят только от признаков пользователя; это позволяет вычислять $c_u(t)$ в разные моменты, не изменяя саму схему сегментации.

Конкретный алгоритм построения орбиталей (обучение модели, извлечение правил с помощью Monoforest, семантическая разметка сегментов) подробно описан в отдельной главе, посвящённой методу Orbitals. В рамках настоящей главы мы будем считать, что такая сегментация уже выполнена и множество орбиталей $\mathcal{C}$ задано.

1.2 Limited LTV и долгосрочный эффект

Цель онлайн-экспериментов часто формулируется как оценка *долгосрочного эффекта* воздействия на ценность пользователя. Прямое измерение пожизненной ценности (LTV) затруднено из-за длинных горизонтов наблюдения и высокой дисперсии, поэтому используется понятие *ограниченной* пожизненной ценности (limited LTV, ILTV), задаваемой на фиксированном прогножном интервале.

Для пользователя u и момента времени t обозначим через $r_u(t)$ выручку, сгенерированную пользователем в момент t . Пусть

$$\mathcal{F}(t, T_F) = (t, t + T_F]$$

— прогнозный горизонт длины T_F , начинающийся в момент t . Тогда ILTV пользователя u в момент t определяется как

$$R_u(t) = \sum_{t' \in \mathcal{F}(t, T_F)} r_u(t').$$

Для множества пользователей P сумма ILTV равна

$$R(t; P) = \sum_{u \in P} R_u(t).$$

На практике точное предсказание абсолютных значений $R_u(t)$ затруднено из-за сезонности, конкурентной среды и других внешних факторов. Во

многих прикладных задачах достаточно оценить не абсолютную, а относительную прибавку в ожидаемой выручке, которую обеспечивает рассматриваемое изменение.

Ожидание ILTV случайного пользователя из множества P обозначим через

$$V(t; P) = \mathbb{E}[R_u(t) \mid u \sim P].$$

Чтобы связать ILTV с орбиталями, рассмотрим распределение пользователей множества P по орбиталям в момент времени t . Обозначим через $D(t; P)$ соответствующее распределение, а через

$$p(c \mid D(t; P)) = \mathbb{P}(c_u(t) = c \mid u \sim P)$$

— вероятность того, что случайно выбранный пользователь из P **принадлежит** орбитали c .

Для каждой орбитали $c \in \mathcal{C}$ определим условное ожидание ILTV:

$$V_c(t) = \mathbb{E}[R_u(t) \mid c_u(t) = c].$$

Тогда ожидание ILTV по множеству P может быть записано как

$$V(t; P) = \sum_{c \in \mathcal{C}} V_c(t) p(c \mid D(t; P)).$$

Ключевое структурное предположение подхода состоит в том, что относительный потенциал орбиталей по выручке стабилен во времени. Формально предполагается, что для любых t и любой пары орбиталей c, c' выполнено

$$\log V_c(t) - \log V_{c'}(t) = \kappa_{c,c'},$$

где $\kappa_{c,c'}$ — константа, зависящая только от пары орбиталей. Это эквивалентно тому, что существуют положительные множители $V_c > 0$ и общий временной множитель $V_o(t) > 0$ такие, что

$$V_c(t) = V_c \cdot V_o(t) \quad \text{для всех } c \in \mathcal{C}, t.$$

В этой мультипликативной схеме $V_o(t)$ отражает общие временные факторы, одинаково влияющие на все орбитали, а V_c — устойчивые различия в ILTV между орбиталями. Подобная декомпозиция согласуется со стандартными мультипликативными моделями временных рядов [9] и в рассматриваемой задаче поддерживается эмпирическими наблюдениями (пикрил).

При таких обозначениях

$$V(t; P) = \sum_{c \in \mathcal{C}} V_c(t) p(c \mid D(t; P)) = V_o(t) \sum_{c \in \mathcal{C}} V_c p(c \mid D(t; P)).$$

Рассмотрим два распределения D_1 и D_2 . Относительная разница в ожидании ILTV между ними равна

$$r_V(D_2 \parallel D_1) = \frac{V(t; D_2) - V(t; D_1)}{V(t; D_1)} = \frac{\sum_c V_c p(c \mid D_2) - \sum_c V_c p(c \mid D_1)}{\sum_c V_c p(c \mid D_1)}. \quad (1)$$

Общий временной множитель $V_o(t)$ сокращается, поэтому относительный эффект определяется только различием в составе орбиталей и их ценности V_c . Это соотношение лежит в основе оценки долгосрочного эффекта через перераспределение пользователей между орбиталями.

1.3 Переходы между орбиталями в А/Б-экспериментах

В постановке А/Б-эксперимента требуется сравнить ILTV тестовой и контрольной групп.

Будем считать, что обе популяции достаточно велики и в теории являются несмещёнными, так что в момент начала эксперимента T_S распределения пользователей по орбиталям $D_A(T_S)$ и $D_B(T_S)$ совпадают.

Пусть T_E — момент окончания эксперимента. Тогда интервал $[T_S, T_E]$ задаёт период действия экспериментального воздействия, а ILTV оценивается на прогнозном горизонте

$$\mathcal{F}(T_E, T_F) = (T_E, T_E + T_F].$$

Согласно формуле (1), для сравнения групп можно использовать от-

носительное различие в ожидании ILTV. Однако вместо непосредственного сравнения орбитальных распределений в момент T_E удобно рассматривать их изменение за время эксперимента. Для этого вводится скорректированная метрика

$$r_{V\text{-corr}}(D_B \parallel D_A) = \frac{(V(T_E; D_B) - V(T_S; D_B)) - (V(T_E; D_A) - V(T_S; D_A))}{V(T_E; D_A)}.$$

Такое преобразование позволяет использовать изменение распределений за время эксперимента, а не только их значения в конечной точке. Этот приём уменьшает шум, связанный со стартовой точкой эксперимента. Хотя в теории при корректной рандомизации распределения $D_A(T_S)$ и $D_B(T_S)$ совпадают, на практике орбитальное распределение в начальный момент является случайным вектором, и потому между контрольной и тестовой группами могут возникать небольшие различия. Скорректированная метрика частично компенсирует эти различия.

С точки зрения поведения пользователей это означает анализ переходов между орбиталями **на интервале** $[T_S, T_E]$. Для каждой группы $g \in \{A, B\}$ можно рассматривать эмпирическую матрицу переходов

$$P_{c \rightarrow c'}^{(g)} = \mathbb{P}(c_u(T_E) = c' \mid c_u(T_S) = c, u \in P_g),$$

которая описывает вероятность перехода из орбитали c в орбиталь c' за время эксперимента. Различия этих матриц между группами приводят к различиям в итоговых распределениях $D_A(T_E)$ и $D_B(T_E)$, а значит, и в значениях r_V и $r_{V\text{-corr}}$.

Таким образом, в рамках **нашего подхода** задача оценки долгосрочного эффекта в А/Б-эксперименте сводится к сравнению того, как экспериментальное воздействие изменяет распределение пользователей по орбитальям и как эти изменения затем отражаются на ожидании ILTV.

1.4 Поставленные задачи оценки и эталонные методы

В рамках предложенного подхода оценки естественным образом возникают две основные задачи:

1. **Присвоение орбиталей.** Необходимо построить сегментацию пользователей на орбитали по их историческим признакам так, чтобы принадлежность к орбитали отражала устойчивые поведенческие паттерны, предсказывающие будущую выручку. Иными словами, орбиталь должна служить компактным суррогатом индивидуального поведения пользователя с точки зрения ILTV.
2. **Оценка ценности орбиталей.** Требуется получить оценки инвариантных по времени множителей $\hat{V}_c$, характеризующих относительную ценность каждой орбитали $c \in \mathcal{C}$ с точки зрения ожидаемой ILTV. Эти множители связывают поведенческие сегменты с их вкладом в будущую выручку.

При наличии орбитальной принадлежности пользователей и набора $\{\hat{V}_c\}_{c \in \mathcal{C}}$ можно вычислять метрики r_V и $r_{V\text{-corr}}$ по наблюдаемым распределениям пользователей по орбиталям в начале и в конце эксперимента. Таким образом, относительный эффект по ILTV оказывается выражен через изменения распределения по орбиталям и их ценности, что позволяет оценивать долгосрочное воздействие эксперимента, не дожидаясь полного завершения прогнозного горизонта $\mathcal{F}(T_E, T_F)$.

Для оценки качества орбитального оценщика рассмотрим два естественных эталонных подхода.

(1) Прямое наблюдение ограниченной LTV. Наиболее прямой способ оценки долгосрочного эффекта состоит в том, чтобы дождаться, пока прогнозное окно $\mathcal{F}(T_E, T_F)$ полностью завершится, и затем непосредственно вычислить реализованную ограниченную LTV каждого пользователя:

$$R_u(T_E) = \sum_{t' \in \mathcal{F}(T_E, T_F)} r_u(t').$$

Далее средние значения $R_u(T_E)$ в контрольной и тестовой группах используются для оценки относительного эффекта.

В идеализированной постановке такой оценщик является несмещённым: он опирается на фактические денежные потоки и не зависит от модель-

ных предположений. Однако на практике это свойство может нарушаться, если за длительный период наблюдения поведение пользователей в группах меняется по-разному (например, из-за перекрёстных запусков других экспериментов, маркетинговых активностей или сдвига состава аудитории). Кроме того, прямое наблюдение ограниченной LTV страдает от высокой дисперсии, поскольку распределение выручки по пользователям обычно имеет тяжёлые хвосты.

(2) Сильная предсказательная модель. Альтернативный эталонный подход состоит в построении супервизируемой модели, предсказывающей $R_u(T_E)$ по признакам пользователя, наблюдаемым к моменту T_E . Такая модель стремится максимально использовать информацию о текущем состоянии пользователя (частота и давность активности, структура трат, признаки вовлечённости и т.п.), чтобы оценить его будущую ограниченную LTV.

Если модель хорошо специфицирована и обучена на репрезентативных данных, она даёт оценщик с существенно меньшей дисперсией по сравнению с прямым наблюдением: индивидуальные шумовые колебания денежных потоков сглаживаются за счёт агрегации информации в признаках. Однако на практике такой подход чувствителен к ряду факторов: ошибкам спецификации модели, сдвигу распределений признаков между обучением и применением (covariate shift), переобучению и другим источникам систематического смещения. В результате оценки эффекта лечения могут быть искажены даже при визуально хорошем качестве предсказаний.

Орбитальная оценка. Предлагаемый орбитальный оценщик на основе метрик r_V и $r_{V\text{-corr}}$ занимает промежуточное положение между этими двумя крайними подходами. С одной стороны, он опирается на структурное модельное предположение

$$V_c(t) = V_c \cdot V_o(t),$$

которое в реальных данных может выполняться лишь приближённо. Если это предположение нарушается, оценки, основанные на орбиталях, могут наследовать небольшое смещение.

С другой стороны, поведение пользователей сводится к относительно небольшому числу орбиталей, и требуется оценить лишь низкоразмерный вектор параметров $\{V_c\}_{c \in \mathcal{C}}$. Это радикально снижает размерность задачи по сравнению с полностью индивидуальными предсказаниями $R_u(T_E)$ и позволяет существенно уменьшить дисперсию оценок эффекта. По сути, орбитали играют роль агрегированных суррогатов: они достаточно грубо аппроксимируют сложное пространство поведенческих траекторий, но при этом сохраняют различия между типичными режимами поведения, важные с точки зрения будущей ценности.

Таким образом, орбитальный оценщик реализует осознанный компромисс между небольшим модельным смещением и существенным снижением дисперсии. В контексте А/В-экспериментов, где статистическая мощность часто ограничивает возможность обнаружения слабых, но практически значимых эффектов, такой компромисс оказывается особенно важен: снижение дисперсии метрики непосредственно повышает чувствительность теста при фиксированном объеме выборки. [\[file:97\]](#)

В **экспериментальной части работы** этот компромисс будет квантифицирован на реальных данных: будут сопоставлены прямое наблюдение ограниченной LTV, сильная предсказательная модель и орбитальный оценщик по смещению, дисперсии и способности корректно выявлять эффект в А/А- и А/В-экспериментах.

Выводы

Жизнь — тлен.

Заключение

... см. классические модели Pareto/NBD и их развитие [4, 21, 22, 5].

Список литературы

- [1] Thomas Crook, Brian Frasca, Ron Kohavi, and Roger Longbotham. 2009. Seven pitfalls to avoid when running controlled experiments on the web. 1105–1114. doi:10.1145/1557019.1557139
- [2] Pavel Dmitriev, Somit Gupta, Dong Kim, and Garnet Vaz. 2017. A Dirty Dozen: Twelve Common Metric Interpretation Pitfalls in Online Controlled Experiments. 1427–1436. doi:10.1145/3097983.3098024
- [3] Weitao Duan, Shan Ba, and Chunzhe Zhang. 2021. Online Experimentation with Surrogate Metrics: Guidelines and a Case Study. In *Proceedings of the 14th ACM International Conference on Web Search and Data Mining (WSDM '21)*. ACM, 193–201. doi:10.1145/3437963.3441737
- [4] Peter S. Fader and Bruce G. S. Hardie. 2005. Counting your customers "the easy way": An alternative to the Pareto/NBD model. *Marketing Science* 24, 2 (2005), 275–284. doi:10.1287/mksc.1040.0098
- [5] Peter S. Fader and Bruce G. S. Hardie. 2010. Customer-base analysis in a discrete-time noncontractual setting. *Marketing Science* 29, 6 (2010), 1096–1108. doi:10.1287/mksc.1090.0553
- [6] Peter S. Fader, Bruce G. S. Hardie, and Ka Lok Lee. 2005. RFM and CLV: Using Iso-Value Curves for Customer Base Analysis. *Journal of Marketing Research* 42, 4 (2005), 415–430. doi:10.1509/jmkr.2005.42.4.415
- [7] Leo Guelman, Montserrat Guillen, and Ana Perez-Marin. 2015. Uplift Random Forests. *Cybernetics and Systems* 46 (05 2015). doi:10.1080/01969722.2015.1012892
- [8] F. Maxwell Harper, Gediminas Adomavicius, Michael D. Ekstrand, and George Karypis. 2024. Long-term Off-Policy Evaluation and Learning. *arXiv preprint arXiv:2404.15691* (2024). doi:10.48550/arXiv.2404.15691

- [9] R.J. Hyndman and G. Athanasopoulos. 2018. *Forecasting: principles and practice*. OTexts. https://books.google.ru/books?id=_bBhDwAAQBAJ
- [10] Ron Kohavi, Bill Harlam, Roger Walker, and Yang Wu. 2016. Pitfalls of Long-Term Online Controlled Experiments. In *2016 IEEE International Conference on Big Data (Big Data)*. IEEE, 1520–1529. doi:10.1109/BigData.2016.7840954
- [11] Ron Kohavi and Roger Longbotham. 2015. Focusing on the Long-term: It’s Good for Users and Business. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1721–1721. doi:10.1145/2783258.2788609
- [12] Ron Kohavi, Diane Tang, and Ya Xu. 2020. *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*. Cambridge University Press. doi:10.1017/9781108653985
- [13] Margaux Luck, Tristan Sylvain, Joseph Paul Cohen, Héloïse Cardinal, Andrea Lodi, and Yoshua Bengio. 2018. Learning to rank for censored survival data. *CoRR* abs/1806.01984. arXiv:1806.01984 <http://arxiv.org/abs/1806.01984>
- [14] Oded Netzer and James Lattin. 2008. A Hidden Markov Model of Customer Relationship Dynamics. *Marketing Science* 27 (03 2008). doi:10.1287/mksc.1070.0294
- [15] Juan Camilo Ordúz. 2023. Cohort Revenue & Retention Analysis: A Bayesian Approach. *arXiv preprint arXiv:2303.15224* (2023). <https://arxiv.org/abs/2303.15224>
- [16] Phillip E. Pfeifer and Robert L. Carraway. 2000. Modeling customer relationships as Markov chains. *Journal of Interactive Marketing* 14, 2 (2000), 43–55. doi:10.1002/(SICI)1520-6653(200021)14:2<43::AID-DIR4>3.0.CO;2-H

- [17] Ross L. Prentice. 1989. Surrogate endpoints in clinical trials: definition and operational criteria. *Statistics in Medicine* 8, 4 (1989), 431–440. doi:10.1002/sim.4780080407
- [18] Thomas Reutterer, Andreas Mild, Martin Natter, and Alfred Taudes. 2006. A dynamic segmentation approach for targeting and customizing direct marketing campaigns. *Journal of Interactive Marketing* 20, 3 (2006), 43–57. doi:10.1002/dir.20066
- [19] Saharon Rosset, Einat Neumann, Uri Eick, and Nurit Vatnik. 2003. Customer Lifetime Value Models for Decision Support. *Data Mining and Knowledge Discovery* 7, 3 (07 2003), 321–339. doi:10.1023/A:1024036305874
- [20] Soheil Sadeghi, Somit Gupta, Stefan Gramatovici, Jiannan Lu, Hao Ai, and Ruhan Zhang. 2021. Novelty and Primacy: A Long-Term Estimator for Online Experiments. *CoRR* abs/2102.12893 (2021). arXiv:2102.12893 <https://arxiv.org/abs/2102.12893>
- [21] David C. Schmittlein, Donald G. Morrison, and Richard Colombo. 1987. Maximum likelihood estimation for the NBD and Pareto/NBD models using the EM algorithm. *Marketing Science* 6, 4 (1987), 319–332. doi:10.1287/mksc.6.4.319
- [22] David C. Schmittlein, Donald G. Morrison, and Richard A. Peterson. 1987. Customer base analysis: An individual-level approach to modeling churn, retention, and customer lifetime value. (1987).
- [23] Nilesh Tripuraneni, Lee Richardson, Alexander D’Amour, Jacopo Soriano, and Steve Yadlowsky. 2024. Choosing a Proxy Metric from Past Experiments. arXiv:2309.07893 [stat.ME] <https://arxiv.org/abs/2309.07893>
- [24] Ya Xu, Nanyu Chen, Addrian Fernandez, An Deng, Zheng Gou, and Jan Koenig. 2015. The impact of experimental design on online controlled experiments: An empirical study. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1255–1264. doi:10.1145/2783258.2783294

- [25] Vickie Zhang, Michael Zhao, , Maria Dimakopoulou, Anh Le, and Nathan Kallus. 2024. Evaluating the Surrogate Index as a Decision-Making Tool Using 200 A/B Tests at Netflix. (2024). arXiv:2311.11922 [stat.AP] <https://arxiv.org/abs/2311.11922>
- [26] Vladislav Zhuzhel, Rodrigo Rivera-Castro, Nina Kaploukhaya, Liliya Mironova, Alexey Zaytsev, and Evgeny Burnaev. 2021. COHORTNEY: Non-Parametric Clustering of Event Sequences. *arXiv preprint arXiv:2104.01440* (2021). <https://arxiv.org/abs/2104.01440>