

Санкт–Петербургский государственный университет

ИВАНОВ Иван Иванович

Выпускная квалификационная работа

***То, на что ты уже через полгода будешь смотреть со
слезами***

Уровень образования: бакалавриат

Направление 01.03.02 «Прикладная математика и информатика»

Основная образовательная программа СВ.5005.2015 «Прикладная
математика, фундаментальная информатика и программирование»

Профиль «Исследование и проектирование систем управления
и обработки сигналов»

Научный руководитель:

профессор, кафедра компьютерных технологий
и систем, д.ф. - м.н. Веремей Евгений Игоревич

Рецензент:

профессор, кафедра компьютерных технологий
и систем, д.ф. - м.н. Веремей Евгений Игоревич

Санкт-Петербург

2026 г.

Содержание

Введение	4
Постановка задачи	7
Обзор литературы	9
Глава 1. Формальная постановка задачи и предположения	14
1.1. Орбитали как целеориентированные сегменты	14
1.2. Limited LTV и долгосрочный эффект	15
1.3. Переходы между орбиталями в А/Б-экспериментах	17
Глава 2. Поставленные задачи оценки и эталонные методы	19
Глава 3. Целевая сегментация пользователей на орбитали	22
3.1. Постановка задачи сегментации	22
3.1.1 Общая схема сегментации	22
3.1.2 Определение целевой метрики	23
3.1.3 Формирование поведенческих признаков	23
3.2. Извлечение правил из ансамбля деревьев	24
3.2.1 Обучение ансамбля деревьев	24
3.2.2 Полиномиальное представление ансамбля деревьев	24
3.2.3 Извлечение и отбор логических правил	25
3.3. Построение и интерпретация орбиталей	27
3.3.1 Построение орбиталей по набору правил	27
3.3.2 Семантическая разметка орбиталей	27
3.3.3 Свойства и роль орбиталей	28
Глава 4. Экспериментальное исследование	29
4.1. Корпус экспериментов и схема оценивания	29
4.2. Эмпирическая проверка мультипликативного допущения	31
4.3. Точность и надёжность долгосрочных прогнозов	32
4.4. Анализ конкретного эксперимента: BNPL	34
4.5. Сопоставление с эталонными методами	34
4.6. Обсуждение и ограничения	36
Выводы	38

Заключение	40
Список литературы	42

Введение

Оценка долгосрочного эффекта онлайн-экспериментов признаётся одной из наиболее сложных задач как в академических исследованиях, так и в индустриальной практике. Классические подходы к А/Б-тестированию хорошо приспособлены для измерения краткосрочных эффектов воздействий, однако с трудом улавливают отложенные и устойчивые сдвиги в ключевых бизнес-метриках, таких как пожизненная ценность клиента (customer lifetime value, LTV или CLV) [1, 12]. Ряд работ показывает, что оптимизация исключительно под краткосрочные исходы рискованна: ранние выигрыши могут со временем уменьшаться или сменяться потерями вследствие изменения паттернов вовлечённости пользователей [21, 11, 10, 2].

Чтобы преодолеть этот разрыв, в литературе развивается несколько направлений. Одно из наиболее заметных — использование *суррогатных* (проху) метрик, когда краткосрочные наблюдаемые индикаторы применяются для предсказания долгосрочных исходов. Так, в исследованиях Google предложены подходы к построению оптимальных прокси-метрик на основе истории прошлых А/Б-тестов: показано, что композитные суррогаты заметно улучшают принятие решений по сравнению с одиночной метрикой [24]. В работах LinkedIn продемонстрированы методы аппроксимации долгосрочных метрик по краткосрочным ковариатам, позволяющие сокращать длительность экспериментов при сохранении предсказательной способности [3]. Netflix развивает это направление, обучая прокси-метрики на исторических экспериментах и подчёркивая важность согласованности направления краткосрочных сигналов и долгосрочных целей [26].

Параллельное направление связано с поведенческой сегментацией клиентской базы. Классический RFM-анализ (Recency, Frequency, Monetary value) на протяжении десятилетий используется как базовый инструмент сегментации: он группирует пользователей по характеристикам транзакционного поведения и даёт интуитивно понятные и применимые на практике инсайты для бизнес-стратегии [6, 20]. Дальнейшее развитие этих идей — модели жизненного цикла клиента (Pareto/NBD, BG/NBD) и подходы к описанию динамики поведения, в том числе скрытые марковские модели отношений с

клиентом [22, 23, 4, 5, 15].

В настоящей работе предлагается подход, в котором долгосрочные эффекты А/Б-экспериментов оцениваются через *целеориентированную* поведенческую сегментацию пользователей. Каждый сегмент определяется условиями над пользователем и историей его активности в системе; сами условия подбираются так, чтобы внутри сегмента группировались пользователи с похожими целевыми характеристиками (например, GMV, удержанием, интенсивностью вовлечённости). Такие сегменты мы называем *орбиталями* и анализируем не столько сами их статические характеристики, сколько *траектории* пользователей между ними. В отличие от статических когорт, такая динамическая сегментация постоянно обновляет принадлежность пользователей к сегментам, преодолевая ограничения традиционных подходов, не учитывающих временную динамику [19, 27, 16]. По духу метод близок к работам, в которых поведение пользователей описывается как скрытый марковский процесс [15, 17], однако вместо фиксированных скрытых состояний используются непосредственно орбитали, а наблюдаемым итогом эксперимента становится финальное распределение пользователей по ним.

В работе формулируются три ключевых результата:

- вводится понятие *орбиталей* — целеориентированной поведенческой сегментации, обеспечивающей надёжную и интерпретируемую оценку долгосрочных эффектов по коротким экспериментам;
- формализуется использование *динамики переходов* между орбиталями как механизма причинного вывода, связывающего ближайшие поведенческие изменения с будущей ценностью;
- метод валидируется на реальных данных А/Б-тестов крупномасштабной e-commerce платформы, и демонстрируется, что орбитали улучшают качество принимаемых решений, не нарушая темпа быстрых экспериментальных циклов.

Предлагаемый подход закрывает важный разрыв в современном экспериментировании: рассогласованность между быстрыми циклами разработки

продукта и стратегической потребностью смотреть на долгосрочные эффекты. Опираясь на наблюдаемые траектории пользователей, орбитали дают прозрачную и удобную в эксплуатации альтернативу непрозрачным суррогатным моделям и при этом не требуют проведения длительных экспериментов.

Постановка задачи

В современных платформах А/Б-эксперименты вынуждены давать ответ за ограниченное время — от нескольких дней до нескольких недель, — тогда как ключевые бизнес-метрики (удержание, пожизненная ценность пользователя) формируются на горизонтах, существенно превышающих длительность одного теста [12, 10, 25]. Прямые оценки долгосрочного эффекта через продолжительные эксперименты сопровождаются ростом стоимости, операционных рисков и эффектов выживаемости и потому плохо встраиваются в быстрые циклы разработки [11, 10, 8]. Альтернативные подходы на основе суррогатных моделей опираются на модели «чёрного ящика» и требуют постоянной перекалибровки при изменениях продукта [24, 3, 26]. В результате между быстрыми экспериментальными циклами и стратегической потребностью смотреть на долгосрочные эффекты сохраняется устойчивый разрыв.

Чтобы конкретизировать характер этого разрыва, рассмотрим реальный пример из практики. В рассматриваемом эксперименте пользователям тестовой группы предлагалась возможность «купить сейчас, заплатить позже» (Buy Now, Pay Later, BNPL) в маркетплейсе. На рис. ?? показано, как менялась разница в показателях удержания пользователей контрольной (А) и тестовой (В) групп.

На старте эксперимента уровни удержания в обеих группах были близки. По ходу эксперимента BNPL воспринималась пользователями как ценная функциональность, что приводило к росту удержания в тестовой группе. К моменту завершения эксперимента сформировавшийся разрыв сохранялся в течение длительного периода. Этот пример показывает, что долгосрочные поведенческие паттерны могут меняться *в течение* эксперимента и что соответствующие эффекты допустимо оценивать ещё до его формального окончания: тестовая группа ожидаемо приносит большую ценность независимо от итогового решения по самой функциональности.

Опираясь на этот пример, мы интерпретируем долгосрочный эффект не как ответ на гипотетический вопрос «что произошло бы, если бы эксперимент длился бесконечно?», а более операциональным образом: «как именно

эксперимент уже изменил долгосрочное поведение пользователей?». Такая постановка позволяет работать с фактически наблюдаемыми поведенческими сдвигами и оценивать их до того, как реализуется вся будущая выручка, — именно эта интерпретация лежит в основе предлагаемого метода Orbitals.

Неформально задача исследования состоит в следующем. Дана платформа, на которой проводится А/Б-эксперимент с разделением пользователей на контрольную (А) и тестовую (В) группы; известны их характеристики и история активности до и в течение эксперимента. Требуется построить *целесоориентированную* поведенческую сегментацию пользователей (орбитали) и метод оценки долгосрочного эффекта эксперимента, который удовлетворяет следующим требованиям:

- (i) использует только данные, наблюдаемые в течение самого теста;
- (ii) опирается на изменение распределения пользователей по орбиталам и переходы между ними;
- (iii) сохраняет интерпретируемость относительно исходных поведенческих сегментов;
- (iv) встраивается в существующие пайплайны А/Б-тестирования без существенной перестройки инфраструктуры.

Обзор литературы

Тема диссертации находится на пересечении трёх направлений: оценки долгосрочного эффекта онлайн-экспериментов, моделирования поведения пользователей и методологии А/Б-тестирования. Ниже разбираются основные из этих направлений, причём внимание уделяется не только их достижениям, но и ограничениям, которые проявляются в задаче масштабируемой и интерпретируемой оценки LTV.

Краткосрочные А/Б-эксперименты и прокси-метрики

А/Б-тестирование давно закрепилось как стандартный инструмент оценки продуктовых изменений на онлайн-платформах [12]. Из-за операционных ограничений большинство экспериментов планируется так, чтобы давать ответ за дни или недели, и команды вынуждены опираться на краткосрочные прокси-метрики — кликабельность (CTR), длительность сессии, немедленную конверсию. Такие показатели удобно измерять, но они нередко слабо связаны с долгосрочными бизнес-исходами.

Эта проблема систематически разбирается в литературе об ошибках интерпретации онлайн-экспериментов. В работе [2] описана характерная подборка типичных «ловушек» (так называемая «dirty dozen»), среди которых — интерпретация краткосрочного выигрыша как устойчивого долгосрочного эффекта. Хрестоматийный пример — увеличение объёма рекламных показов: оно даёт немедленный прирост выручки, но со временем снижает удовлетворённость пользователей и повышает отток. Именно такое рассогласование заставляет искать методы, способные переводить краткосрочные сигналы в надёжные оценки долгосрочного эффекта.

Длительные эксперименты

Самая очевидная стратегия — продлить сам эксперимент. Опыт Netflix [26] и Microsoft [21] показывает, что длительные дизайны действительно позволяют наблюдать отложенные исходы, в первую очередь — изменения удержания и частоты покупок. Однако такие эксперименты дороги, медленно дают ответ

и оставляют бизнес под продолжительным риском. К этому добавляется проблема *выживаемости* (survivorship bias): со временем в окне анализа остаются преимущественно наиболее вовлечённые пользователи, что искажает оценку эффекта на уровне всей популяции.

Суррогатное моделирование долгосрочных эффектов

Чтобы совместить быстрые циклы экспериментирования с потребностью в долгосрочной оценке, развиваются методы *суррогатного моделирования*: долгосрочный исход прогнозируется по краткосрочным поведенческим сигналам. По сути задача сводится к выбору или построению такой метрики (или композитной метрики) на ранних этапах жизненного цикла пользователя, которая сильно коррелирует с будущей ценностью. В индустриальной практике эта конструкция получила название *Surrogate Index* [26]: она ускоряет принятие решений, не разрывая их со стратегическими целями бизнеса.

Современные реализации опираются на машинное обучение и выучивают сложные нелинейные отображения из ранних поведенческих признаков в LTV [8]. На платформах Netflix и Microsoft такие модели используются для прогнозирования последующего вовлечения и выручки по ранним паттернам взаимодействия, а их калибровка проводится на исторических А/Б-тестах для обеспечения надёжности [26, 21].

При всей выразительности эти модели обычно слабо интерпретируемы и требуют значительного объёма исторических данных для калибровки. Кроме того, они опираются на так называемое *предположение суррогатности*: краткосрочная прокси-метрика должна не только коррелировать с долгосрочным исходом, но и полностью опосредовать причинный эффект воздействия на него [26]. Формально это требование сформулировано Prentice [18] в контексте клинических испытаний: все причинные пути от воздействия к итоговому исходу должны проходить исключительно через суррогат. Практика показывает, что суррогатные индексы, обученные на краткосрочных метриках, успешно предсказывают долгосрочные исходы — это подтверждено валидацией более чем на 200 А/Б-тестах [26], — однако само предположение суррогатности трудно проверять, и оно может нарушаться из-за эффектов

новизны, привыкания и скрытых искажающих факторов.

Когортный анализ и поведенческая сегментация

Когортный анализ относится к базовым техникам клиентской аналитики и традиционно применяется для разложения LTV на компоненты: удержание, частоту и денежную ценность (RFM) [20]. Группируя пользователей по общим признакам — например, по месяцу регистрации или уровню активности, — команды получают возможность отслеживать эволюцию ключевых метрик во времени.

В диссертации эта традиция продолжается, но акцент смещается с описательной сегментации на *целеориентированную*. В отличие от статических когортных определений, орбитали выводятся из предсказательной задачи — прогнозирования будущей активности пользователя — с помощью решающих правил, извлечённых из ансамблевых древесных моделей машинного обучения, широко применяемых на практике. Благодаря этому получаемые сегменты остаются интерпретируемыми и одновременно настроены под задачу оценки долгосрочного эффекта.

Важной теоретической опорой для связи RFM-признаков с пожизненной ценностью служит работа Fader, Hardie и Lee [6], в которой вводится понятие *iso-value curves* — линий уровня в пространстве RFM, объединяющих пользователей с одинаковой ожидаемой LTV. Авторы показывают, что разные комбинации давности, частоты и денежной ценности могут соответствовать сопоставимой долгосрочной ценности, и тем самым ставят под сомнение упрощённые сегментационные схемы. Этот результат поддерживает выбранный подход: вместо фиксированных RFM-эвристик отображение поведенческих паттернов в LTV выучивается из данных, что обеспечивает более точное и многогранное представление архетипов пользователей.

Параметрические модели поведения пользователей

Существенный пласт литературы посвящён вероятностным моделям активности и оттока. Среди наиболее известных — Pareto/NBD и BG/NBD [4], описывающие два сопряжённых процесса: интенсивность транзакций и выбы-

тие пользователя. Эти модели позволяют прогнозировать будущие покупки и широко применяются в анализе клиентской базы.

В рамках предварительного исследования мы применяли Pareto/NBD для описания активности пользователей и оценки LTV, выраженной в днях вовлечённости. Модель удовлетворительно воспроизводит агрегированные паттерны удержания, но оказывается менее эффективной при работе с гетерогенной пользовательской популяцией и короткими окнами наблюдения. К этому добавляется характерное ограничение её предпосылок — в частности, постоянной интенсивности выбытия, — которое нередко нарушается в динамичных продуктовых средах.

В более поздних работах изучается применение моделей времени до события и анализа выживаемости для оценки долгосрочных эффектов [14]. Эти подходы, однако, требуют сложного отбора признаков и плохо переносятся на широкий спектр типов экспериментов.

Uplift-моделирование и переходы между состояниями

Uplift-моделирование нацелено на оценку индивидуального эффекта воздействия и служит основой для персонализированных решений. Среди современных подходов выделяется *Uplift Random Forest* [7], расширяющий алгоритм случайного леса за счёт критерия расщепления, ориентированного на гетерогенный эффект. Это позволяет выявлять подгруппы, в которых воздействие оказывает наиболее сильное положительное или отрицательное влияние, при сохранении устойчивости за счёт ансамблирования. Несмотря на потенциал, такие методы чувствительны к шуму и требуют больших объёмов выборки для надёжной оценки эффектов на индивидуальном уровне.

Предлагаемый подход дополняет uplift-моделирование, перенося фокус с индивидуальных эффектов на *групповые переходы* между поведенческими состояниями. Описывая то, как воздействие сдвигает распределение пользователей по орбиталям, мы получаем причинную интерпретацию, устойчивую к шуму и применимую на практике. По духу подход близок к марковским моделям отношений с клиентом [17, 15], но адаптирован к специфике онлайн-экспериментов и краткосрочных интервенций.

Выводы по обзору

Существующие подходы предоставляют богатый инструментарий для оценки долгосрочных эффектов, однако каждое из направлений вынуждено идти на компромисс между интерпретируемостью, масштабируемостью и надёжностью. Длительные эксперименты дают наиболее точную оценку, но дороги и подвержены эффектам выживаемости. Суррогатные модели ускоряют принятие решений ценой интерпретируемости и опираются на сложно проверяемое предположение суррогатности. Параметрические модели поведения и анализ выживаемости строятся на сильных допущениях и плохо переносятся на разнородные эксперименты. Uplift-моделирование требует значительных объёмов данных и оценивает эффект на индивидуальном уровне, что затрудняет его применение для стратегических решений.

Метод Orbitals закрывает обозначенный разрыв: он соединяет прозрачность когортного анализа с предсказательной силой машинного обучения и сводит оценку долгосрочного эффекта к анализу переходов между целеориентированными поведенческими сегментами. Такая постановка естественно опирается на операциональное определение долгосрочного эффекта и требования к методу, которые сформулированы в главе «Постановка задачи».

Глава 1. Формальная постановка задачи и предположения

В этой главе формализуются основные понятия и обозначения, используемые в дальнейшем. Сначала уточняется постановка задачи и вводятся обозначения, затем для формального определения долгосрочного эффекта вводится понятие ограниченной пожизненной ценности (limited LTV, ILTV), после чего показывается как эти конструкции применяются для А/Б эксперимента.

Ключевая идея подхода состоит в том, что долгосрочное воздействие экспериментального изменения проявляется не столько в смене поведения *внутри* орбиталей, сколько в *перераспределении пользователей между орбиталями*. Орбитали задают устойчивые **архетипы поведения**, а сам эффект эксперимента реализуется за счёт того, что доли пользователей **принадлежащих конкретным архетипам** меняются. Это допущение является центральным для предлагаемой схемы и **в экспериментальной части работы** будет поддержано эмпирическими наблюдениями.

Второе важное отличие нашего подхода состоит в **выборе объекта** оценивания. Мы стремимся оценить не гипотетический эффект бесконечно продолжительного воздействия, а тот долгосрочный эффект, который *уже сформировался* к моменту окончания эксперимента. Такая цель согласуется с типичными ограничениями на длительность А/Б-экспериментов и проще реализуема на практике, хотя и не устраняет всех проблем краткосрочного окна (например, эффекта новизны).

1.1 Орбитали как целеориентированные сегменты

В **нашем подходе** поведение пользователей описывается через *орбитали* — поведенческие сегменты, построенные с учётом целевой метрики (**LTV или её прокси**) и определённые интерпретируемыми правилами над признаками пользователя. Сегментация является *целеориентированной* (target-aware): орбитали конструируются так, чтобы хорошо предсказывать будущую ценность, а не только описывать текущие различия пользователей.

Формально множество орбиталей обозначим через $\mathcal{C}$. Для каждого пользователя u и момента времени t определена его орбитальная принадлежность

$c_u(t) \in \mathcal{C}$. Правила, определяющие орбитали, считаются зафиксированными во времени и зависят только от признаков пользователя; это позволяет вычислять $c_u(t)$ в разные моменты, не изменяя саму схему сегментации.

Конкретный алгоритм построения орбиталей (обучение модели, извлечение правил с помощью Monoforest, семантическая разметка сегментов) подробно описан в отдельной главе, посвящённой методу Orbitals. В рамках настоящей главы мы будем считать, что такая сегментация уже выполнена и множество орбиталей $\mathcal{C}$ задано.

1.2 Limited LTV и долгосрочный эффект

Цель онлайн-экспериментов часто формулируется как оценка *долгосрочного эффекта* воздействия на ценность пользователя. Прямое измерение пожизненной ценности (LTV) затруднено из-за длинных горизонтов наблюдения и высокой дисперсии, поэтому используется понятие *ограниченной* пожизненной ценности (limited LTV, ILTV), задаваемой на фиксированном прогножном интервале.

Для пользователя u и момента времени t обозначим через $r_u(t)$ выручку, сгенерированную пользователем в момент t . Пусть

$$\mathcal{F}(t, T_F) = (t, t + T_F]$$

— прогнозный горизонт длины T_F , начинающийся в момент t . Тогда ILTV пользователя u в момент t определяется как

$$R_u(t) = \sum_{t' \in \mathcal{F}(t, T_F)} r_u(t').$$

Для множества пользователей P сумма ILTV равна

$$R(t; P) = \sum_{u \in P} R_u(t).$$

На практике точное предсказание абсолютных значений $R_u(t)$ затруднено из-за сезонности, конкурентной среды и других внешних факторов. Во

многих прикладных задачах достаточно оценить не абсолютную, а относительную прибавку в ожидаемой выручке, которую обеспечивает рассматриваемое изменение.

Ожидание ILTV случайного пользователя из множества P обозначим через

$$V(t; P) = \mathbb{E}[R_u(t) \mid u \sim P].$$

Чтобы связать ILTV с орбиталями, рассмотрим распределение пользователей множества P по орбиталям в момент времени t . Обозначим через $D(t; P)$ соответствующее распределение, а через

$$p(c \mid D(t; P)) = \mathbb{P}(c_u(t) = c \mid u \sim P)$$

— вероятность того, что случайно выбранный пользователь из P принадлежит орбитали c .

Для каждой орбитали $c \in \mathcal{C}$ определим условное ожидание ILTV:

$$V_c(t) = \mathbb{E}[R_u(t) \mid c_u(t) = c].$$

Тогда ожидание ILTV по множеству P может быть записано как

$$V(t; P) = \sum_{c \in \mathcal{C}} V_c(t) p(c \mid D(t; P)).$$

Ключевое структурное предположение подхода состоит в том, что относительный потенциал орбиталей по выручке стабилен во времени. Формально предполагается, что для любых t и любой пары орбиталей c, c' выполнено

$$\log V_c(t) - \log V_{c'}(t) = \kappa_{c,c'},$$

где $\kappa_{c,c'}$ — константа, зависящая только от пары орбиталей. Это эквивалентно тому, что существуют положительные множители $V_c > 0$ и общий временной множитель $V_o(t) > 0$ такие, что

$$V_c(t) = V_c \cdot V_o(t) \quad \text{для всех } c \in \mathcal{C}, t.$$

В этой мультипликативной схеме $V_o(t)$ отражает общие временные факторы, одинаково влияющие на все орбитали, а V_c — устойчивые различия в ILTV между орбиталями. Подобная декомпозиция согласуется со стандартными мультипликативными моделями временных рядов [9] и в рассматриваемой задаче поддерживается эмпирическими наблюдениями (пикрил).

При таких обозначениях

$$V(t; P) = \sum_{c \in \mathcal{C}} V_c(t) p(c \mid D(t; P)) = V_o(t) \sum_{c \in \mathcal{C}} V_c p(c \mid D(t; P)).$$

Рассмотрим два распределения D_1 и D_2 . Относительная разница в ожидании ILTV между ними равна

$$r_V(D_2 \parallel D_1) = \frac{V(t; D_2) - V(t; D_1)}{V(t; D_1)} = \frac{\sum_c V_c p(c \mid D_2) - \sum_c V_c p(c \mid D_1)}{\sum_c V_c p(c \mid D_1)}. \quad (1)$$

Общий временной множитель $V_o(t)$ сокращается, поэтому относительный эффект определяется только различием в составе орбиталей и их ценности V_c . Это соотношение лежит в основе оценки долгосрочного эффекта через перераспределение пользователей между орбиталями.

1.3 Переходы между орбиталями в А/Б-экспериментах

В постановке А/Б-эксперимента требуется сравнить ILTV тестовой и контрольной групп.

Будем считать, что обе популяции достаточно велики и в теории являются несмещёнными, так что в момент начала эксперимента T_S распределения пользователей по орбиталям $D_A(T_S)$ и $D_B(T_S)$ совпадают.

Пусть T_E — момент окончания эксперимента. Тогда интервал $[T_S, T_E]$ задаёт период действия экспериментального воздействия, а ILTV оценивается на прогнозном горизонте

$$\mathcal{F}(T_E, T_F) = (T_E, T_E + T_F].$$

Согласно формуле (1), для сравнения групп можно использовать от-

носительное различие в ожидании ILTV. Однако вместо непосредственного сравнения орбитальных распределений в момент T_E удобно рассматривать их изменение за время эксперимента. Для этого вводится скорректированная метрика

$$r_{V\text{-corr}}(D_B \parallel D_A) = \frac{(V(T_E; D_B) - V(T_S; D_B)) - (V(T_E; D_A) - V(T_S; D_A))}{V(T_E; D_A)}. \quad (2)$$

Такое преобразование позволяет использовать изменение распределений за время эксперимента, а не только их значения в конечной точке. Этот приём уменьшает шум, связанный со стартовой точкой эксперимента. Хотя в теории при корректной рандомизации распределения $D_A(T_S)$ и $D_B(T_S)$ совпадают, на практике орбитальное распределение в начальный момент является случайным вектором, и потому между контрольной и тестовой группами могут возникать небольшие различия. Скорректированная метрика частично компенсирует эти различия.

С точки зрения поведения пользователей это означает анализ переходов между орбиталями **на интервале** $[T_S, T_E]$. Для каждой группы $g \in \{A, B\}$ можно рассматривать эмпирическую матрицу переходов

$$P_{c \rightarrow c'}^{(g)} = \mathbb{P}(c_u(T_E) = c' \mid c_u(T_S) = c, u \in P_g),$$

которая описывает вероятность перехода из орбитали c в орбиталь c' за время эксперимента. Различия этих матриц между группами приводят к различиям в итоговых распределениях $D_A(T_E)$ и $D_B(T_E)$, а значит, и в значениях r_V и $r_{V\text{-corr}}$.

Таким образом, в рамках **нашего подхода** задача оценки долгосрочного эффекта в А/Б-эксперименте сводится к сравнению того, как экспериментальное воздействие изменяет распределение пользователей по орбитальям и как эти изменения затем отражаются на ожидании ILTV.

Глава 2. Поставленные задачи оценки и эталонные методы

В рамках предложенного подхода оценки естественным образом возникают две основные задачи:

1. **Присвоение орбиталей.** Необходимо построить сегментацию пользователей на орбитали по их историческим признакам так, чтобы принадлежность к орбитали отражала устойчивые поведенческие паттерны, предсказывающие будущую выручку. Иными словами, орбиталь должна служить компактным суррогатом индивидуального поведения пользователя с точки зрения ILTV.
2. **Оценка ценности орбиталей.** Требуется получить оценки инвариантных по времени множителей $\hat{V}_c$, характеризующих относительную ценность каждой орбитали $c \in \mathcal{C}$ с точки зрения ожидаемой ILTV. Эти множители связывают поведенческие сегменты с их вкладом в будущую выручку.

При наличии орбитальной принадлежности пользователей и набора $\{\hat{V}_c\}_{c \in \mathcal{C}}$ можно вычислять метрики r_V и $r_{V\text{-corr}}$ по наблюдаемым распределениям пользователей по орбиталям в начале и в конце эксперимента. Таким образом, относительный эффект по ILTV оказывается выражен через изменения распределения по орбиталям и их ценности, что позволяет оценивать долгосрочное воздействие эксперимента, не дожидаясь полного завершения прогнозного горизонта $\mathcal{F}(T_E, T_F)$.

Для оценки качества орбитального оценщика рассмотрим два естественных эталонных подхода.

(1) Прямое наблюдение ограниченной LTV. Наиболее прямой способ оценки долгосрочного эффекта состоит в том, чтобы дождаться, пока прогнозное окно $\mathcal{F}(T_E, T_F)$ полностью завершится, и затем непосредственно вычислить

реализованную ограниченную LTV каждого пользователя:

$$R_u(T_E) = \sum_{t' \in \mathcal{F}(T_E, T_F)} r_u(t').$$

Далее средние значения $R_u(T_E)$ в контрольной и тестовой группах используются для оценки относительного эффекта.

В идеализированной постановке такой оценщик является несмещённым: он опирается на фактические денежные потоки и не зависит от модельных предположений. Однако на практике это свойство может нарушаться, если за длительный период наблюдения поведение пользователей в группах меняется по-разному (например, из-за перекрёстных запусков других экспериментов, маркетинговых активностей или сдвига состава аудитории). Кроме того, прямое наблюдение ограниченной LTV страдает от высокой дисперсии, поскольку распределение выручки по пользователям обычно имеет тяжёлые хвосты.

(2) Сильная предсказательная модель. Альтернативный эталонный подход состоит в построении супервизируемой модели, предсказывающей $R_u(T_E)$ по признакам пользователя, наблюдаемым к моменту T_E . Такая модель стремится максимально использовать информацию о текущем состоянии пользователя (частота и давность активности, структура трат, признаки вовлечённости и т.п.), чтобы оценить его будущую ограниченную LTV.

Если модель хорошо специфицирована и обучена на репрезентативных данных, она даёт оценщик с существенно меньшей дисперсией по сравнению с прямым наблюдением: индивидуальные шумовые колебания денежных потоков сглаживаются за счёт агрегации информации в признаках. Однако на практике такой подход чувствителен к ряду факторов: ошибкам спецификации модели, сдвигу распределений признаков между обучением и применением (covariate shift), переобучению и другим источникам систематического смещения. В результате оценки эффекта лечения могут быть искажены даже при визуально хорошем качестве предсказаний.

Орбитальная оценка. Предлагаемый орбитальный оценщик на основе метрик r_V и $r_{V\text{-corr}}$ занимает промежуточное положение между этими двумя крайними подходами. С одной стороны, он опирается на структурное модельное предположение

$$V_c(t) = V_c \cdot V_o(t),$$

которое в реальных данных может выполняться лишь приближённо. Если это предположение нарушается, оценки, основанные на орбиталях, могут наследовать небольшое смещение.

С другой стороны, поведение пользователей сводится к относительно небольшому числу орбиталей, и требуется оценить лишь низкоразмерный вектор параметров $\{V_c\}_{c \in \mathcal{C}}$. Это радикально снижает размерность задачи по сравнению с полностью индивидуальными предсказаниями $R_u(T_E)$ и позволяет существенно уменьшить дисперсию оценок эффекта. По сути, орбитали играют роль агрегированных суррогатов: они достаточно грубо аппроксимируют сложное пространство поведенческих траекторий, но при этом сохраняют различия между типичными режимами поведения, важные с точки зрения будущей ценности.

Таким образом, орбитальный оценщик реализует осознанный компромисс между небольшим модельным смещением и существенным снижением дисперсии. В контексте А/В-экспериментов, где статистическая мощность часто ограничивает возможность обнаружения слабых, но практически значимых эффектов, такой компромисс оказывается особенно важен: снижение дисперсии метрики непосредственно повышает чувствительность теста при фиксированном объёме выборки. [\[file:97\]](#)

В **экспериментальной части работы** этот компромисс будет квантифицирован на реальных данных: будут сопоставлены прямое наблюдение ограниченной LTV, сильная предсказательная модель и орбитальный оценщик по смещению, дисперсии и способности корректно выявлять эффект в А/А- и А/В-экспериментах.

Глава 3. Целевая сегментация пользователей на орбитали

В настоящей главе описывается процедура сегментации пользователей на орбитали, лежащая в основе предлагаемого подхода к оценке долгосрочного эффекта. Основная идея состоит в том, чтобы использовать ансамбль решающих деревьев, обученный на целевой метрике, и затем трансформировать его в компактную и интерпретируемую систему правил, задающую устойчивые поведенческие сегменты.

Под орбиталью далее понимается сегмент пользователей, определяемый набором интерпретируемых правил в пространстве признаков и отражающий характерный **архетип (режим)** поведения. Такая сегментация служит базовым представлением пользовательской **базы** при анализе долгосрочного эффекта через переходы между орбиталями.

3.1 Постановка задачи сегментации

3.1.1 Общая схема сегментации

Сегментация пользователей на орбитали строится **как последовательность нескольких этапов**. Сначала выбирается целевая **метрика (величина)**, относительно которой сегментация должна быть информативной. Затем для каждого пользователя формируется набор признаков, описывающих его поведение на фиксированном историческом интервале.

На следующем шаге обучается ансамбль решающих деревьев, предсказывающий выбранную целевую метрику по указанным признакам. После обучения ансамбль переводится в полиномиальное представление, из которого с помощью фреймворка Monoforest [13] извлекаются наиболее значимые логические правила. На основе отобранных правил строится сокращённая система сегментов, которой далее придаётся семантическая интерпретация в виде орбиталей.

Таким образом, предсказательная модель используется не как конечный инструмент оценивания, а как источник структуры, по которой строится интерпретируемая сегментация пользователей.

3.1.2 Определение целевой метрики

На первом этапе определяется целевая метрика (величина), относительно которой должна быть информативна сегментация. В качестве такой метрики (величины) используется прокси-метрика, связанная с будущей ценностью пользователя. В рассматриваемой постановке в качестве примеров можно указать ограниченную накопленную ценность пользователя или число активных дней за фиксированный период времени.

После выбора целевой метрики обучается ансамбль деревьев, предсказывающий её по историческим признакам пользователя. Однако в дальнейшем для построения сегментации используются не сами индивидуальные предсказания модели, а наиболее существенные элементы её внутренней структуры, которые извлекаются в виде логических правил.

Такой подход ориентирует сегментацию не на абстрактное сходство пользователей, а на различия между ними с точки зрения будущей целевой метрики (величины).

3.1.3 Формирование поведенческих признаков

Для каждого пользователя формируется набор признаков, описывающих его поведение на фиксированном историческом интервале. В базовой постановке используются признаки, рассчитанные за период длиной 30 дней.

В качестве примеров поведенческих признаков можно привести:

- recency — число дней с момента последней активности;
- frequency — число активных дней за наблюдаемый период;
- GMV — суммарную денежную выручку за период;
- и другие агрегированные характеристики поведения пользователя.

Набор признаков проектируется отдельно для каждой системы с учётом продуктовой специфики. Важно, чтобы он обеспечивал достаточно полное описание среднесрочного поведения пользователя и позволял предсказывать выбранную целевую метрику.

3.2 Извлечение правил из ансамбля деревьев

3.2.1 Обучение ансамбля деревьев

На сформированных признаках обучается ансамбль решающих деревьев, реализуемый, в частности, в виде модели CatBoostRegressor, предсказывающей выбранную целевую метрику (величину). В качестве иллюстрации можно рассматривать задачу предсказания числа активных дней пользователя на следующем 30-дневном интервале.

Использование ансамбля деревьев позволяет учитывать сложные нелинейные зависимости между краткосрочным поведением и будущими характеристиками пользователя. За счёт этого модель отражает неоднородность пользовательской базы и выявляет структурные различия между типами пользователей.

Предполагается, что фундаментальные правила сегментации определяются свойствами системы и остаются относительно стабильными во времени.

Поэтому при обучении ансамбля допустимо использовать данные за несколько временных периодов. Существенные изменения продукта, напротив, требуют переобучения ансамбля и, как следствие, пересмотра набора правил.

3.2.2 Полиномиальное представление ансамбля деревьев

Ключевой элемент фреймворка Monoforest заключается в том, что ансамбль решающих деревьев может быть представлен не только как набор деревьев, но и в виде полинома по индикаторам пороговых условий на признаках [13]. Такое представление позволяет перейти от графовой структуры деревьев к единому набору интерпретируемых логических правил.

Рассмотрим одно дерево решений $h(x)$. Оно разбивает пространство признаков на непересекающиеся области, соответствующие листьям дерева. Если каждому листу l сопоставлено значение w_l , то дерево можно записать в виде

$$h(x) = \sum_{l \in \text{leaves}} w_l I\{x \in l\}.$$

Индикатор принадлежности листу определяется набором условий на

пути от корня дерева к этому листу. Пусть элементарное условие имеет вид

$$c(x) = I\{x_{i(c)} > b(c)\}.$$

Тогда прохождению по правой ветви соответствует множитель $c(x)$, по левой — множитель $1 - c(x)$. Индикатор каждого листа можно представить в виде произведения таких множителей.

После раскрытия скобок дерево допускает представление в виде суммы мономов:

$$h(x) = \sum_{M \in 2^C} w_M \prod_{c \in M} c(x),$$

где C — множество элементарных условий, а M — некоторое их подмножество. Таким образом, каждое дерево представляется как сумма элементарных логических правил, каждое из которых соответствует комбинации пороговых условий.

Для ансамбля деревьев

$$H(x) = \sum_{t=1}^T h_t(x)$$

получается аналогичное полиномиальное представление:

$$H(x) = \sum_{M \in 2^C} w_M \prod_{c \in M} c(x),$$

где коэффициенты w_M агрегируют вклад одинаковых мономов, возникающих в разных деревьях ансамбля [13].

Такое представление позволяет рассматривать ансамбль как единый набор логических правил и служит основой для количественной оценки значимости каждого правила и последующего отбора наиболее информативных.

3.2.3 Извлечение и отбор логических правил

После перехода к полиномиальному представлению отдельные мономы могут рассматриваться как интерпретируемые логические правила. Каждое

такое правило соответствует комбинации пороговых условий на признаках пользователя и задаёт определённую область в пространстве признаков.

Формально моном записывается в виде

$$M_k = \prod_j I\{x_{i(j)} \geq \theta_j\}.$$

Произведение индикаторов означает одновременное выполнение всех соответствующих условий, то есть моном задаёт правило вида: пользователь относится к заданной области, если одновременно выполняется набор пороговых ограничений на его признаки.

Например, правило может иметь вид

$$I\{\text{frequency} \geq 10\} \cdot I\{\text{recency} \leq 3\} \cdot I\{\text{GMV} \geq 5000\},$$

что соответствует пользователям с высокой частотой активности, недавней последней активностью и значительным уровнем монетизации.

Для оценки значимости правила Monoforest сопоставляет каждому моному вес

$$\text{score}(M_k) = w_k^2 \cdot \text{coverage}(M_k),$$

где w_k характеризует вклад монома в значение модели, а $\text{coverage}(M_k)$ — долю объектов выборки, для которых выполняется соответствующее правило [13].

Такое определение веса сочетает две естественные характеристики правила: величину влияния на предсказание и распространённость на данных. Наибольший интерес представляют мономы с большими значениями w_k , которые одновременно существенно влияют на модель и выполняются для заметной доли пользователей.

Все мономы ранжируются по величине весов $\text{score}(M_k)$, после чего выбирается ограниченный набор наиболее значимых правил. В результате полная структура ансамбля заменяется компактным представлением через небольшое число информативных логических конструкций.

3.3 Построение и интерпретация орбиталей

3.3.1 Построение орбиталей по набору правил

После ранжирования мономов по весам $\text{score}(M_k)$ выбирается верхняя часть списка, например K наиболее значимых правил. Этот набор образует сокращённое описание ансамбля, сохраняющее его ключевые структурные элементы.

Далее по выбранным правилам строится упрощённая сегментационная структура. Практически она может быть реализована в виде необязательно бинарного дерева решений или эквивалентной системы вложенных логических условий. Каждому конечному листу такой структуры соответствует кандидатный сегмент пользователей.

Пользователь относится к сегменту в зависимости от того, какие из отобранных правил выполняются для его признаков. Тем самым исходный ансамбль решающих деревьев заменяется компактной системой сегментов, определяемых небольшим набором наиболее значимых логических правил.

3.3.2 Семантическая разметка орбиталей

Полученные на предыдущем этапе сегменты целиком определяются данными и структурой ансамбля, однако сами по себе не всегда имеют очевидный содержательный смысл. Для придания сегментам интерпретируемости им присваиваются осмысленные семантические метки, которые затем используются в последующем анализе.

В качестве примеров таких меток можно привести *weak*, *active*, *paid*, *active&paid* и *whale*. Отнесение сегмента к той или иной категории основано на анализе распределений ключевых метрик внутри сегмента.

Так, сегмент с высокой частотой активности, недавней последней активностью и очень большим значением GMV естественно интерпретировать как *whale*. Сегмент с умеренной активностью и положительной монетизацией — как *active&paid*. Сегменты с минимальной активностью относятся к категории *weak*.

Отдельно выделяется сегмент *out*, включающий пользователей, лежа-

щих вне рассматриваемого исторического окна (например, не проявлявших активности в этот период). Такой сегмент представляет понятный, но вспомогательный поведенческий архетип, поэтому в дальнейшем он используется главным образом для описания состава выборки и далее не включается в интерпретацию основных орбиталей.

Полученное множество семантически размеченных сегментов образует набор орбиталей, используемый в формальной модели и в экспериментальном анализе.

3.3.3 Свойства и роль орбиталей

Построенная сегментация обладает рядом свойств, важных для оценки долгосрочного эффекта.

Во-первых, она ориентирована на целевую метрику: орбитали формируются как сегменты, информативные относительно будущей ценности пользователя, а не как произвольные кластеры поведения.

Во-вторых, орбитали интерпретируемы, поскольку задаются ограниченным набором правил и снабжены содержательными метками. Это делает их пригодными не только для вычислительных процедур, но и для анализа со стороны продуктовых и бизнес-команд.

В-третьих, итоговая сегментация детерминирована и может применяться к пользователям в режиме, близком к реальному времени. Благодаря этому орбитали могут быть интегрированы в инфраструктуру онлайн-экспериментов.

Тем самым ансамбль деревьев, обладающий свойствами «чёрного ящика», преобразуется в прозрачную схему сегментации, основанную на интерпретируемых правилах. Полученные орбитали служат базовой единицей анализа, через которую далее описываются изменения структуры пользовательской базы и оценивается долгосрочный эффект экспериментального воздействия.

Глава 4. Экспериментальное исследование

В предыдущих главах был формально определён **орбитальный оценитель** долгосрочного эффекта на основе метрик r_V (1) и $r_{V\text{-corr}}$ (2), описана процедура построения орбиталей (раздел 3) и сформулирована гипотеза о компромиссе между смещением и дисперсией (раздел ??). Настоящая глава замыкает эту конструкцию эмпирически.

Исследование преследует четыре последовательные цели:

1. эмпирически проверить мультипликативное допущение $V_c(t) = V_c \cdot V_o(t)$ из раздела 1.2;
2. оценить точность орбитальных прогнозов r_V и $r_{V\text{-corr}}$ относительно фактического ILTV-эффекта, наблюдаемого на горизонте $\mathcal{F}(T_E, T_F)$;
3. проверить согласованность орбитальных оценок с краткосрочными метриками, уже применяемыми в продуктовой практике;
4. квантифицировать компромисс смещение–дисперсия путём сопоставления с двумя эталонными подходами, введёнными в разделе ??.

Все эксперименты проводятся на крупной платформе электронной коммерции; объём каждого эксперимента — миллионы пользователей. Если не оговорено иное, прогнозный горизонт $T_F = 30$ дней.

Отсутствие утечки информации. Данные на прогнозном горизонте $\mathcal{F}(T_E, 30)$ не используются при построении орбитальной оценки. Метод опирается только на признаки пользователей до начала эксперимента, их орбитальные метки в моменты T_S и T_E , а также на наблюдаемые переходы внутри экспериментального окна $[T_S, T_E]$. Реализованная ограниченная пожизненная ценность (ILTV) на горизонте $\mathcal{F}(T_E, 30)$ используется исключительно как отложенный эталон для валидации.

4.1 Корпус экспериментов и схема оценивания

Эмпирическая база — корпус значимых A/B-экспериментов, для которых доступна верифицированная реализованная ILTV $R_u(T_E)$ на горизонте

$\mathcal{F}(T_E, 30)$. Различные подмножества корпуса используются для разных проверок: для сопоставления предсказанного и фактического эффекта (раздел 4.3) отбирается 21 эксперимент, удовлетворяющий условиям полноты данных; для проверки согласованности с краткосрочной метрикой — 28 экспериментов.

Рассматриваемые интервенции охватывают качественно разные продуктовые воздействия: ценообразование, оптимизацию интерфейса и пользовательских сценариев, обновления моделей поиска и ранжирования, а также запуск новых функциональностей — в частности, опции «Buy Now, Pay Later» (BNPL), подробно разбираемой в 4.4.

Для каждого эксперимента доступны:

- поведенческие признаки пользователей за 30 дней до T_S , в соответствии с разделом 3.1.3: *recency*, *frequency*, *GMV* и другие агрегированные характеристики поведения;
- орбитальные метки $c_u(T_S)$ и $c_u(T_E)$, полученные по сегментации, описанной в разделе 3; в качестве сегментов используются *weak*, *active*, *paid*, *active&paid*, *whale* и вспомогательный *out*;
- эмпирические матрицы переходов $\hat{P}_{c \rightarrow c'}^{(g)}$ для $g \in \{A, B\}$ и производные распределения $D_g(T_S)$, $D_g(T_E)$;
- реализованная *ILTV* $R_u(T_E)$ для пользователей обеих групп, используемая исключительно как отложенный эталон.

В соответствии с разделом ?? орбитальные множители $\{\hat{V}_c\}_{c \in \mathcal{C}}$ оцениваются на историческом окне, не пересекающемся с экспериментальным; их устойчивость во времени проверяется в 4.2.

Сопоставление ведётся с двумя эталонами:

Прямое наблюдение ILTV: относительная разница средних $R_u(T_E)$ между группами (раздел ??, пункт (1));

Краткосрочная суррогатная метрика: средняя выручка на пользователя в окне $[T_S, T_E]$ (*Average GMV per User*); используется для проверки согласованности с действующими продуктовыми показателями.

Все статистические выводы получаются непараметрической бутстрэп-процедурой с 10 000 псевдовыборок. На рисунках приведены 70% бутстрэп-интервалы — они служат для визуального сопоставления точечных оценок; решения о статистической значимости далее принимаются отдельно при уровне значимости $\alpha = 0.1$.

4.2 Эмпирическая проверка мультипликативного допущения

Допущение $V_c(t) = V_c \cdot V_o(t)$, введённое в разделе 1.2, играет роль ключевого структурного предположения: именно оно обеспечивает сокращение общего временного множителя $V_o(t)$ в формуле (1) и позволяет переводить изменения распределения по орбиталям в оценку относительного ILTV-эффекта. Поскольку допущение является модельным, его эмпирическая проверка необходима до содержательного использования $\hat{V}_c$.

Для проверки используется историческое окно длиной 1.5 года, не пересекающееся с экспериментальным корпусом. Для каждой орбитали $c \in \mathcal{C}$ и каждого опорного момента t вычисляется оценка $\hat{V}_c(t)$, после чего анализируются попарные отношения $\hat{V}_c(t)/\hat{V}_{c'}(t)$ во времени (см. рис. ??).

Результаты показывают, что относительный порядок орбиталей по ILTV и масштаб различий между ними остаются устойчивыми, несмотря на сезонные колебания и системные изменения платформы. Это позволяет:

- принять мультипликативное допущение как рабочее приближение в рассматриваемом домене;
- использовать единый набор $\{\hat{V}_c\}_{c \in \mathcal{C}}$, агрегирующий $\hat{V}_c(t)$ по разным t , при подстановке в r_V и $r_{V\text{-corr}}$.

Тем самым эмпирически подтверждается и более общий тезис из вводной части раздела 1: долгосрочное воздействие проявляется в первую очередь через перераспределение пользователей *между* орбиталями, а не через изменение поведения *внутри* них.

4.3 Точность и надёжность долгосрочных прогнозов

Под *ILTV-эффектом* здесь и далее понимается относительная разница ожиданий ILTV между тестовой и контрольной группами на горизонте $\mathcal{F}(T_E, 30)$ — в обозначениях раздела 1.2 это r_V или $r_{V\text{-corr}}$ в зависимости от формулировки.

Сопоставление предсказанного и фактического эффекта. В качестве отправной точки рассматривается revenue-based вариант методики, в котором роль целевой величины при построении орбиталей (в смысле раздела 3.1.2) играет накопленная ограниченная LTV. На рис. ?? для 21 эксперимента сопоставлены предсказанный $\hat{r}_{V\text{-corr}}$ и фактический ILTV-эффект.

В рассматриваемой выборке знаки предсказанного и фактического эффектов в большинстве экспериментов совпадают. Вместе с тем фактические оценки по $R_u(T_E)$ обладают высокой дисперсией: бутстрэп-интервалы наблюдаемого GMV-эффекта нередко оказываются широкими, что соответствует характеристике прямого эталона из раздела ??, пункт (1) (тяжёлые хвосты распределения выручки), и затрудняет однозначную интерпретацию экспериментов с умеренным эффектом.

Для дополнительной проверки направления и относительной силы эффекта используется frequency-based вариант методики, в котором целевой величиной выступает число активных дней — вторая иллюстративная целевая величина из раздела 3.1.2. Эта величина не заменяет финансовую ILTV, но обладает существенно меньшей дисперсией и даёт независимую проверку поведенческой составляющей эффекта в случаях, когда GMV-оценка слишком волатильна (см. рис. ??).

Согласованность статистических выводов по знаку и значимости дополнительно иллюстрируется матрицами ошибок (табл. ??) при уровне значимости $\alpha = 0.1$.

В revenue-based варианте все статистически значимые положительные прогнозы соответствуют неотрицательным фактическим эффектам: противоположных по знаку статистически значимых решений в рассматриваемом корпусе не наблюдается. Это согласуется с тем, что было заявлено в ?? при-

менительно к снижению риска ошибочных рекомендаций.

Frequency-based вариант обладает более высокой чувствительностью: он выявляет больше положительных эффектов ценой нескольких расхождений с наблюдаемыми статистическими выводами по выручке; противоположных по знаку статистически значимых решений он также не порождает.

В совокупности на рассматриваемом корпусе орбитальный подход демонстрирует три свойства, обещанных в ??:

1. **Согласованность по направлению:** ни одно статистически значимое положительное предсказание не соответствует статистически значимому отрицательному фактическому эффекту;
2. **Снижение дисперсии:** 70% бутстрэп-интервалы $r_{V\text{-corr}}$ оказываются, как правило, в $\approx 30\text{--}50\%$ уже соответствующих интервалов прямого эталона по $R_u(T_E)$;
3. **Повышенная чувствительность:** анализ переходов между орбиталями выявляет устойчивые сдвиги, не различимые по краткосрочным агрегатам GMV.

Согласованность с краткосрочной суррогатной метрикой. Орбитальные оценки сопоставляются со средней выручкой на пользователя в окне $[T_S, T_E]$ на 28 экспериментах (см. табл. ??).

В случаях, когда обе метрики фиксируют статистически значимый эффект, направления выводов совпадают; статистически значимых противоречий между ними не наблюдается. Дополнительно примерно в 21.4% экспериментов **Orbitals** обнаруживает значимый эффект там, где средняя выручка на пользователя его не различает. Эти случаи соответствуют изменениям, воздействующим не на немедленную монетизацию, а на структуру переходов между орбиталями (улучшения пользовательских сценариев, элементы программ лояльности и т. п.).

4.4 Анализ конкретного эксперимента: BNPL

Запуск опции «Buy Now, Pay Later» позволяет проиллюстрировать центральный тезис раздела 1: эффект экспериментального воздействия проявляется как сдвиг распределения пользователей между орбиталями. На горизонте 41 дня в тестовой группе наблюдались повышенные вероятности переходов в орбитали *active&paid* и *whale* относительно контрольной группы (см. табл. ??).

В терминах раздела 1.3 это соответствует систематическому различию эмпирических матриц переходов $\hat{P}^{(B)}$ и $\hat{P}^{(A)}$, приводящему к различию итоговых распределений $D_B(T_E)$ и $D_A(T_E)$ и, как следствие, к ненулевому значению $r_{V\text{-corr}}$. Существенно, что наибольшие различия наблюдаются у пользователей со средним уровнем трат, что даёт интерпретируемый продуктовый вывод о потенциале таргетированного онбординга для этой аудитории.

Frequency-based вариант методики предсказал $\hat{r}_{V\text{-corr}} = +1.076\%$; фактическое значение аналогичного частотного эффекта на горизонте $\mathcal{F}(T_E, 30)$ составило $+0.789\%$, относительная ошибка прогноза — порядка 36% (см. рис. ??, панель ??). Несмотря на завышение абсолютной величины, метод корректно восстанавливает знак и порядок эффекта при существенно более узких бутстрэп-интервалах, чем у прямого эталона. С практической точки зрения возможность раннего и устойчивого выявления направления долгосрочного эффекта согласуется с ролью орбитального оценщика, обозначенной в ??: повышение чувствительности теста при ограниченном объёме выборки.

В этом сценарии краткосрочная метрика *Average GMV per User* не обладает достаточной разрешающей способностью, чтобы отделить первичное принятие новой опции от формирования устойчивого паттерна поведения. В отличие от неё, $r_{V\text{-corr}}$ непосредственно отражает изменение траекторий пользователей между орбиталями.

4.5 Сопоставление с эталонными методами

В этом разделе закрывается обещание, сформулированное в разделе ??: компромисс смещение–дисперсия квантифицируется на реальных данных. Сопоставляются три семейства оценок:

- орбитальные оценщики r_V и $r_{V\text{-corr}}$;
- прямой эталон по реализованному $R_u(T_E)$ (раздел ??, пункт (1));
- сильная индивидуальная предсказательная модель (раздел ??, пункт (2)).

Сильная предсказательная модель. В качестве индивидуальной модели используется CatBoostRegressor, обучаемый предсказывать $R_u(T_E)$ по тому же набору поведенческих признаков, что и орбитальная методика (раздел 3.1.3). Обучение проводится на выборке порядка сотен тысяч пользователей с разбиением 70/30; функция потерь и метрика — RMSE; число итераций бустинга — 100, скорость обучения — 0.2, глубина деревьев — 6. Для эксперимента модель применяется к пользователям обеих групп в момент T_E , порождая предсказания $\tilde{R}_u$, по которым формируется относительная разница r_{pred} и её скорректированный аналог $r_{\text{pred-corr}}$ (по аналогии с $r_{V\text{-corr}}$).

Сценарии и результаты. Сравнение проводится на двух сценариях:

A/A-тест: нулевой истинный эффект; объём выборки сопоставим с реальным экспериментом. Позволяет оценить уровень ложных срабатываний и дисперсию оценщиков.

A/B-эксперимент BNPL: ненулевой эффект; объём — десятки тысяч пользователей в каждой группе. Позволяет сопоставить чувствительность методов.

Результаты (см. рис. ??) воспроизводят теоретический прогноз раздела ??:

- в A/A-сценарии орбитальные оценщики остаются близкими к нулю и обладают существенно меньшей дисперсией, чем прямой эталон и индивидуальная модель; в этих альтернативах фиксируются ложные положительные бутстрэп-эффекты, ожидаемые в силу высокой дисперсии и модельных смещений соответственно;

- в BNPL-сценарии $r_{V\text{-corr}}$ согласуется с $r_{\text{pred-corr}}$ по знаку и порядку величины эффекта, но обладает существенно меньшей дисперсией, чем оба эталона.

Тем самым эмпирически воспроизведён компромисс, заявленный в разделе ???: небольшое модельное смещение (в случае приближённой выполнимости мультипликативного допущения из 1.2) обменивается на существенное снижение дисперсии за счёт перехода от индивидуальных предсказаний R_u к низкоразмерному параметру $\{V_c\}_{c \in \mathcal{C}}$.

С целью воспроизводимости результатов открытая реализация **Orbitals** опубликована вместе с обезличенным набором дневных пользовательских логов более чем 1 млн пользователей. Код и данные доступны в публичном репозитории.¹

4.6 Обсуждение и ограничения

Эмпирические результаты согласуются с теоретическими ожиданиями предыдущих глав по трём ключевым пунктам: подтверждается мультипликативное допущение из раздела 1.2; орбитальный оценщик снижает дисперсию относительно прямого эталона и индивидуальной модели, как заявлено в разделе ???; устойчивость сегментации, постулированная в разделах 1.1 и 3.2.1, не нарушается на рассматриваемом горизонте.

Подход опирается на два явных допущения, ограничивающих область его применимости:

Стабильность сегментации (1.1, 3.2.1): поведенческие определения орбиталей сохраняют сопоставимый смысл во времени. Выраженная сезонность, изменение состава аудитории или крупные изменения продукта могут потребовать переобучения ансамбля и пересмотра $\mathcal{C}$ и $\{\hat{V}_c\}$.

Симметрия внешних факторов: внешние воздействия в окне $\mathcal{F}(T_E, T_F)$ влияют на контрольную и тестовую группы симметрично. При нарушении этого условия $r_{V\text{-corr}}$ может оказаться смещённым.

¹<https://github.com/orbitals-acc/orbitals-framework>

Отдельной осторожности требует интерпретация экспериментов, целенаправленно воздействующих на узкие сегменты пользовательской базы (например, на отдельные орбитали): в таких случаях мультипликативное допущение может локально нарушаться и требовать дополнительной диагностики.

Несмотря на отмеченные ограничения, проведённое исследование позволяет заключить, что при корректной калибровке **Orbitals** реализует анонсированный в ?? компромисс между смещением и дисперсией и пригоден в качестве интерпретируемого инструмента ранней оценки долгосрочного эффекта продуктовых интервенций.

Выводы

В ходе выполнения работы были получены следующие основные результаты.

1. Разработан и формально описан фреймворк **Orbitals** — целеориентированная RFM-сегментация пользователей на поведенческие архетипы (орбитали), обладающие двумя ключевыми свойствами: предсказательной способностью относительно ограниченной пожизненной ценности (ILTV) и чувствительностью к экспериментальным воздействиям.
2. Предложен орбитальный оценщик долгосрочного эффекта А/В-эксперимента на основе метрик r_V и $r_{V\text{-corr}}$, формализующих долгосрочный эффект через перераспределение пользователей между орбиталями и их относительные ценности $\{V_c\}_{c \in \mathcal{C}}$.
3. Сформулировано и эмпирически подтверждено мультипликативное допущение $V_c(t) = V_c \cdot V_o(t)$, позволяющее математически отделить сезонные колебания метрик от поведенческих сдвигов, вызванных продуктовым воздействием. На историческом окне в 1.5 года относительный порядок орбиталей по ILTV и масштаб различий между ними оставались устойчивыми.
4. На корпусе из 21 значимого А/В-эксперимента крупной платформы электронной коммерции показано, что орбитальный оценщик:
 - корректно восстанавливает направление долгосрочного эффекта — ни в одном из рассмотренных экспериментов статистически значимый положительный прогноз не соответствовал статистически значимому отрицательному фактическому эффекту (при уровне значимости $\alpha = 0.1$);
 - снижает дисперсию оценки в 1.5–2.5 раза по сравнению с прямым наблюдением реализованной ILTV и с сильной индивидуальной предсказательной моделью;

- обеспечивает повышенную чувствительность — в $\sim 21\%$ экспериментов обнаруживает значимый эффект там, где краткосрочная метрика *Average GMV per User* его не различает.
5. На примере эксперимента BNPL продемонстрирована интерпретируемость метода: долгосрочный эффект объясняется конкретными изменениями в матрицах переходов — ростом вероятностей перехода в орбитали *active&paid* (+2.7%) и *whale* (+8.7%) и снижением доли пользователей в низкоактивных состояниях (−2.6%).
 6. Проведено сопоставление с двумя эталонными методами и эмпирически воспроизведён компромисс смещение–дисперсия: небольшое модельное смещение обменивается на существенное снижение дисперсии за счёт перехода в низкоразмерное пространство орбиталей.
 7. Реализована открытая программная библиотека и опубликован обезличенный набор данных более чем 1 млн пользователей, обеспечивающие воспроизводимость результатов.
 8. Установлены границы применимости метода: требование стабильности орбиталей во времени и условие симметричного воздействия внешних факторов на группы. Метод неприменим без дополнительной диагностики для интервенций, целенаправленно воздействующих на отдельные орбитали.

Заключение

Точная оценка долгосрочных эффектов в А/В-тестировании остаётся одной из ключевых проблем для платформ, выстраивающих процесс принятия продуктовых решений на основе данных. Краткосрочные метрики позволяют быстро итерироваться, но систематически не улавливают истинного влияния интервенций на пожизненную ценность пользователя; прямое наблюдение реализованной ILTV даёт статистически шумную оценку и требует длительных периодов наблюдения, замедляющих продуктовый цикл.

В настоящей работе предложен фреймворк **Orbitals** — целеориентированная поведенческая сегментация, позволяющая оценивать долгосрочный эффект А/В-экспериментов быстрее, надёжнее и интерпретируемее существующих подходов. Центральная идея состоит в отказе от ожидания реализации долгосрочных денежных потоков в пользу анализа немедленного изменения траекторий пользователей между устойчивыми поведенческими архетипами. Если относительные ценности орбиталей остаются стабильными во времени, то долгосрочный эффект можно оценивать уже в момент окончания эксперимента, не дожидаясь полного наблюдения будущей LTV.

Тестирование на реальных данных крупной платформы электронной коммерции подтвердило эффективность подхода. Орбитальный оценщик позволяет получать надёжные ранние сигналы о долгосрочных последствиях продуктовых изменений без расширения экспериментального окна. За счёт агрегирования на уровне орбиталей дисперсия оценки снижается до 2.5 раз, что конвертируется в повышенную чувствительность на тех же объёмах выборки. При этом метод сохраняет прозрачность: результат эксперимента описывается через конкретные переходы пользователей между поведенческими состояниями, что позволяет аналитикам не только видеть *величину* эффекта, но и понимать *механизм* его возникновения.

Важным практическим свойством подхода является его встраиваемость в существующие пайплайны экспериментирования. Краткосрочные метрики продолжают выполнять роль быстрых операционных индикаторов, тогда как орбитальный оценщик работает как дополнительный слой анализа, дающий ранний сигнал о долгосрочном эффекте. Это особенно ценно для из-

менений, которые не приводят к немедленному росту выручки, но смещают траектории пользователей в сторону более ценных состояний.

Вместе с тем предложенный метод не является универсальной заменой полноценного долгосрочного наблюдения. Его корректность зависит от устойчивости сегментации и от приближённого выполнения мультипликативного допущения. Кроме того, для каждого нового продукта требуется индивидуальный инжиниринг поведенческих признаков, а допущение об условной независимости от будущих внешних факторов (сезонности, промо-акций) должно систематически мониториться в эксплуатации.

Перспективы дальнейших исследований видятся в нескольких направлениях.

Динамические орбитали: расширение фреймворка для поддержки изменяющихся во времени определений орбиталей, адаптирующихся к сдвигам пользовательского поведения и эволюции платформы.

Байесовское оценивание ILTV: включение количественной оценки неопределённости в моделирование поведения пользователей для повышения робастности выводов, особенно в условиях ограниченных выборок и тяжёлых хвостов распределения выручки.

Интеграция с каузальной оценкой: объединение фреймворка **Orbitals** с методами контрфактического обучения для дальнейшего повышения предсказательной точности и расширения класса допустимых интервенций.

Подводя итог, фреймворк **Orbitals** предоставляет простое, масштабируемое и интерпретируемое решение для интеграции оценки долгосрочных эффектов в стандартные процессы A/B-тестирования. Фокусируясь на поведенчески осмысленных архетипах и их динамике, метод позволяет видеть долгосрочные последствия продуктовых изменений уже на ранних этапах эксперимента — и тем самым принимать решения, которые являются не только быстрыми, но и стратегически обоснованными.

Список литературы

- [1] Thomas Crook, Brian Frasca, Ron Kohavi, and Roger Longbotham. 2009. Seven pitfalls to avoid when running controlled experiments on the web. 1105–1114. doi:10.1145/1557019.1557139
- [2] Pavel Dmitriev, Somit Gupta, Dong Kim, and Garnet Vaz. 2017. A Dirty Dozen: Twelve Common Metric Interpretation Pitfalls in Online Controlled Experiments. 1427–1436. doi:10.1145/3097983.3098024
- [3] Weitao Duan, Shan Ba, and Chunzhe Zhang. 2021. Online Experimentation with Surrogate Metrics: Guidelines and a Case Study. In *Proceedings of the 14th ACM International Conference on Web Search and Data Mining (WSDM '21)*. ACM, 193–201. doi:10.1145/3437963.3441737
- [4] Peter S. Fader and Bruce G. S. Hardie. 2005. Counting your customers "the easy way": An alternative to the Pareto/NBD model. *Marketing Science* 24, 2 (2005), 275–284. doi:10.1287/mksc.1040.0098
- [5] Peter S. Fader and Bruce G. S. Hardie. 2010. Customer-base analysis in a discrete-time noncontractual setting. *Marketing Science* 29, 6 (2010), 1096–1108. doi:10.1287/mksc.1090.0553
- [6] Peter S. Fader, Bruce G. S. Hardie, and Ka Lok Lee. 2005. RFM and CLV: Using Iso-Value Curves for Customer Base Analysis. *Journal of Marketing Research* 42, 4 (2005), 415–430. doi:10.1509/jmkr.2005.42.4.415
- [7] Leo Guelman, Montserrat Guillen, and Ana Perez-Marin. 2015. Uplift Random Forests. *Cybernetics and Systems* 46 (05 2015). doi:10.1080/01969722.2015.1012892
- [8] F. Maxwell Harper, Gediminas Adomavicius, Michael D. Ekstrand, and George Karypis. 2024. Long-term Off-Policy Evaluation and Learning. *arXiv preprint arXiv:2404.15691* (2024). doi:10.48550/arXiv.2404.15691
- [9] R.J. Hyndman and G. Athanasopoulos. 2018. *Forecasting: principles and practice*. OTexts. https://books.google.ru/books?id=_bBhDwAAQBAJ

- [10] Ron Kohavi, Bill Harlam, Roger Walker, and Yang Wu. 2016. Pitfalls of Long-Term Online Controlled Experiments. In *2016 IEEE International Conference on Big Data (Big Data)*. IEEE, 1520–1529. doi:10.1109/BigData.2016.7840954
- [11] Ron Kohavi and Roger Longbotham. 2015. Focusing on the Long-term: It’s Good for Users and Business. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1721–1721. doi:10.1145/2783258.2788609
- [12] Ron Kohavi, Diane Tang, and Ya Xu. 2020. *Trustworthy Online Controlled Experiments: A Practical Guide to A/B Testing*. Cambridge University Press. doi:10.1017/9781108653985
- [13] Igor Kuralenok, Vasilii Ershov, and Igor Labutin. 2019. MonoForest framework for tree ensemble analysis. 32 (2019). https://proceedings.neurips.cc/paper_files/paper/2019/file/1b9a80606d74d3da6db2f1274557e644-Paper.pdf
- [14] Margaux Luck, Tristan Sylvain, Joseph Paul Cohen, Héloïse Cardinal, Andrea Lodi, and Yoshua Bengio. 2018. Learning to rank for censored survival data. *CoRR* abs/1806.01984. arXiv:1806.01984 <http://arxiv.org/abs/1806.01984>
- [15] Oded Netzer and James Lattin. 2008. A Hidden Markov Model of Customer Relationship Dynamics. *Marketing Science* 27 (03 2008). doi:10.1287/mksc.1070.0294
- [16] Juan Camilo Ordúz. 2023. Cohort Revenue & Retention Analysis: A Bayesian Approach. *arXiv preprint arXiv:2303.15224* (2023). <https://arxiv.org/abs/2303.15224>
- [17] Phillip E. Pfeifer and Robert L. Carraway. 2000. Modeling customer relationships as Markov chains. *Journal of Interactive Marketing* 14, 2 (2000), 43–55. doi:10.1002/(SICI)1520-6653(200021)14:2<43::AID-DIR4>3.0.CO;2-H

- [18] Ross L. Prentice. 1989. Surrogate endpoints in clinical trials: definition and operational criteria. *Statistics in Medicine* 8, 4 (1989), 431–440. doi:10.1002/sim.4780080407
- [19] Thomas Reutterer, Andreas Mild, Martin Natter, and Alfred Taudes. 2006. A dynamic segmentation approach for targeting and customizing direct marketing campaigns. *Journal of Interactive Marketing* 20, 3 (2006), 43–57. doi:10.1002/dir.20066
- [20] Saharon Rosset, Einat Neumann, Uri Eick, and Nurit Vatnik. 2003. Customer Lifetime Value Models for Decision Support. *Data Mining and Knowledge Discovery* 7, 3 (07 2003), 321–339. doi:10.1023/A:1024036305874
- [21] Soheil Sadeghi, Somit Gupta, Stefan Gramatovici, Jiannan Lu, Hao Ai, and Ruhan Zhang. 2021. Novelty and Primacy: A Long-Term Estimator for Online Experiments. *CoRR* abs/2102.12893 (2021). arXiv:2102.12893 <https://arxiv.org/abs/2102.12893>
- [22] David C. Schmittlein, Donald G. Morrison, and Richard Colombo. 1987. Maximum likelihood estimation for the NBD and Pareto/NBD models using the EM algorithm. *Marketing Science* 6, 4 (1987), 319–332. doi:10.1287/mksc.6.4.319
- [23] David C. Schmittlein, Donald G. Morrison, and Richard A. Peterson. 1987. Customer base analysis: An individual-level approach to modeling churn, retention, and customer lifetime value. (1987).
- [24] Nilesh Tripuraneni, Lee Richardson, Alexander D’Amour, Jacopo Soriano, and Steve Yadlowsky. 2024. Choosing a Proxy Metric from Past Experiments. arXiv:2309.07893 [stat.ME] <https://arxiv.org/abs/2309.07893>
- [25] Ya Xu, Nanyu Chen, Addrian Fernandez, An Deng, Zheng Gou, and Jan Koenig. 2015. The impact of experimental design on online controlled experiments: An empirical study. In *Proceedings of the 21st ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 1255–1264. doi:10.1145/2783258.2783294

- [26] Vickie Zhang, Michael Zhao, , Maria Dimakopoulou, Anh Le, and Nathan Kallus. 2024. Evaluating the Surrogate Index as a Decision-Making Tool Using 200 A/B Tests at Netflix. (2024). arXiv:2311.11922 [stat.AP] <https://arxiv.org/abs/2311.11922>
- [27] Vladislav Zhuzhel, Rodrigo Rivera-Castro, Nina Kaploukhaya, Liliya Mironova, Alexey Zaytsev, and Evgeny Burnaev. 2021. COHORTNEY: Non-Parametric Clustering of Event Sequences. *arXiv preprint arXiv:2104.01440* (2021). <https://arxiv.org/abs/2104.01440>